

第63回計算言語学会年次大会 (ACL 2025)
Proceedings of the 63rd Annual Meeting of the Association for
Computational Linguistics

Volume 1: Long Papers, pp. 29330–29355, July 27 – August 1, 2025

DeepReview

人間のような深い思考プロセスによる
LLM ベースの論文レビューの改善

Minjun Zhu^{1,2,†}, Yixuan Weng^{2,†},
Linyi Yang³, Yue Zhang^{2,*}

¹浙江大学 (Zhejiang University)

²西湖大学工学部 (School of Engineering, Westlake University)

³ユニバーシティ・カレッジ・ロンドン (University College London)

本論文は、LLMベースの学術論文レビューの信頼性向上を目指し、構造化された多
段階推論フレームワークを提案する。
データセット・モデル・ベンチマークは公開予定。

目次

要旨

1. [はじめに \(Introduction\)](#)
2. [関連研究 \(Related Work\)](#)
3. [データ収集 \(Data Collection\)](#)
4. [手法 \(Methodology\)](#)
5. [実験 \(Experiments\)](#)
6. [結論 \(Conclusions\)](#)
7. [限界 \(Limitations\)](#)
8. [倫理的配慮 \(Ethical Considerations\)](#)
9. [謝辞 \(Acknowledgements\)](#)
- [参考文献 \(References\)](#)

要旨 (Abstract)

Claim: 本研究は人間レビュアーのLLMによる置き換えを主張するものではなく、ピアレビューにおけるLLMの活用を探るものである。

大規模言語モデル（LLM）は科学研究の評価、特に自動論文レビューにおいてますます活用されるようになってきている。しかし、既存の LLM ベースのレビューシステムは、ドメイン専門知識の制限、幻覚的な推論、構造化された評価の欠如といった重大な課題に直面している。これらの課題に対処するため、我々は専門レビュアーを模倣する多段階フレームワーク **DeepReview** を提案する。これは構造化分析、文献検索、証拠に基づく議論 (evidence-based argumentation) を統合したものである。構造化アノテーション付きのキュレーション済みデータセット **DeepReview-13K** を用いて学習された **DeepReviewer-14B** は、より少ないトークン数で CycleReviewer-70B を上回る。最高性能の Best モードでは、GPT-o1 および DeepSeek-R1 との比較評価においてそれぞれ 88.21% と 80.20% の勝率を達成する。本研究は LLM ベースの論文レビューにおける新しいベンチマークを確立するものであり、すべてのリソースは公開予定である。

本研究では、構造化された中間的推論ステップと最終評価を含む 13K 規模のデータセット *DeepReview-13K* を提案する。これに基づき、Fast・Standard・Best という 3 つの推論モードを備えた 14B パラメータモデル *DeepReviewer-14B* を学習した。さらに、定量評価（評価値予測、品質ランキング、論文選択）と LLM ベースの定性評価を包含する 1.2K サンプルからなるベンチマーク *DeepReview-Bench* を構築した。

広範な実験により、DeepReviewer-14B は複数次元で優れた性能を示すことが実証された。既存システム（CycleReviewer-70B、GPT-o1、Deepseek-R1 など）と比較して、Score 指標（Rating MSE: 44.80% 改善）、Ranking 指標（Spearman: 6.04% 改善）、Selection 指標（Accuracy: 1.80% 改善）のすべてにおいて大幅な向上を達成した。LLM-as-a-judge による評価では、GPT-o1 および DeepSeek-R1 に対して 80% 以上の勝率を達成している。特筆すべき点は、明示的な口バストネス学習を行っていないにもかかわらず、敵対的攻撃に対して強い耐性を示すことである。さらに、Test-Time Scaling の分析により、推論パスと応答長を調整することで DeepReviewer の性能をさらに向上できることが明らかになった。

1. はじめに (Introduction)

ピアレビューは科学的進歩の基盤であり、研究が出版される前に専門家によって新規性 (novelty)、信頼性 (reliability)、厳密性が評価されることを保証するものである (Alberts et al., 2008)。研究投稿数が増加するにつれ、大規模言語モデル (LLM) はレビュアーを支援する有望なツールとなりつつある (Yang et al., 2024; Chris et al., 2024; Li et al., 2024b; Scherbakov et al., 2024; Si et al., 2025)。例えば、ICLR 2025 カンファレンスでは、レビュアーへのフィードバック提供を支援する LLM ベースシステムが導入されている (ICLR Blog, 2024)。

近年の研究では、LLM ベースのレビューシステムを改善する 2 つの主要なアプローチが探求されている。すなわち、(1) AI-Scientist (Chris et al., 2024) や AgentReview (Jin et al., 2024a) に代表される、LLM 駆動エージェントを用いてピアレビュー過程をシミュレートする手法、および (2) ReviewMT (Tan et al., 2024a) や CycleReviewer (Weng et al., 2025) のような既存のピアレビュー基盤からの大規模データセットで学習されたオープンソースモデルを開発する手法、である。

これらの進展にもかかわらず、現行システムはいくつかの重大な限界を抱えている。すなわち、投稿の欠陥を包括的に特定することが困難で表面的なフィードバックになりがちであること (Zhou et al., 2024a)、証拠に基づく根拠付けを欠いていること (Zhuang et al., 2025)、明確な実行可能な提案を提供できないこと (Ye et al., 2024; Du et al., 2024)、さらにプロンプトエンジニアリングによる脆弱性のために不正確な評価に陥りやすいこと (Ye et al., 2024; Weng et al., 2025) などである。

堅牢なフィードバックは科学的進展とピアレビューの健全性にとって不可欠であるが、信頼性の高い評価フレームワークの開発には 2 つの重大な課題がある。(1) 構造化された論文レビューデータセットの不足 — 入手可能なオープンレビューデータセットの多くは集約されたレビューと判定のみを含み、専門家の詳細な評価過程を捉えていないため、LLM が体系的なレビューの推論連鎖を学習する能力を制限し、ショートカット学習や敵対的操作への脆弱性を高めている。(2) LLM 固有の制約 — ドメイン知識の制限、動的な知識更新機構の欠如、適切な検証なしには幻覚的な内容を生成する傾向 (Schintler et al., 2023; Drori and Te'eni, 2024; Weng et al., 2024) は、複雑な科学的内容を評価する能力を著しく損なう (Wang et al., 2020; Yuan et al., 2021)。

これらの課題に対処するため、我々は **DeepReview** を提案する。これは、新規性評価 (novelty assessment)、多次元評価基準、信頼性検証を統合することで、専門家のレビュー過程と密接に整合する構造化された多段階レビューフレームワークである。検索とランキング (Asai et al., 2024)、自己検証 (Weng et al., 2023)、自己反省 (Ji et al., 2023) を統合した包括的なデータ合成パイプラインを開発し、LLM による提案の妥当性と堅牢性を確保する。この手法により、論文レビューの推論と意思決定に対するより深い洞察を可能となる。結果として得られるデータセット *DeepReview-13K* は、元の研究論文、構造化された中間レビュー段階、最終評価から構成される。これに基づき、3 つの推論モード (Fast、Standard、Best) を提供する *DeepReviewer-14B* モデルを学習する。これにより、ユーザーは効率と応答品質のバランスを取ることができる。さらに、定量的側面 (評価値予測、品質ラン

キング、論文選択) と LLM 評価による定性レビューの両方を評価する 1.2K サンプルを含む包括的ベンチマーク *DeepReview-Bench* を構築する。

広範な実験により、DeepReviewer-14B の複数次元における優れた性能が実証された。既存システム (CycleReviewer-70B、GPT-o1、Deepseek-R1 など) と比較して、大幅な改善を達成している (後述のスコア、ランキング、選択の各指標、および LLM-as-a-judge 評価における 80% 以上の勝率など)。DeepReviewer は、明示的な口バストネス学習を行っていないにもかかわらず、敵対的攻撃に対し顕著な耐性を示す。さらに、Test-Time Scaling 分析により、推論パスと応答長を調整することで DeepReviewer の性能を向上できることが明らかになった。

本研究は、自動原稿評価における根本的な課題に取り組む構造化フレームワークである *DeepReview* を通じて、LLM ベースのレビューシステムのための堅牢な基盤を確立する。詳細な推論連鎖を含むデータセット *DeepReview-13K* と、自動論文レビューのためのベンチマーク *DeepReview-Bench* を導入する。これらのリソースに基づき、*DeepReviewer-14B* モデルは敵対的攻撃に対する強い耐性を維持しつつ、既存手法に対する大幅な改善を示し、自動科学的評価に対する我々の構造化アプローチの有効性を検証する。我々のコード、モデル、データは利用規約に従って公開される予定である。

2. 関連研究 (Related Work)

2.1 LLM における推論

大規模言語モデル (Achiam et al., 2023; Touvron et al., 2023; Bai et al., 2023) の登場は、複雑な科学的課題 (Hendrycks et al., 2021; Zhu et al., 2025) の解決に向けた新たな支援を提供した。当初、*Scratchpads* や *chain-of-thought* (思考の連鎖) (Akyürek et al., 2022; Nye et al., 2021; Wei et al., 2022) は LLM に「考えさせる」ことを促した。この技法はさまざまな推論タスクで活用されている。これを基盤として、自己一貫性 (self-consistency) (Wang et al., 2023)、自己検証 (self-verification) (Weng et al., 2023)、自己反省 (self-reflection) (Madaan et al., 2024) といった一連の研究が、推論中に言語モデルにより多くの思考過程を出力するよう促した。その後、OpenAI の o1 モデル (Jaech et al., 2024) やさまざまなオープンソースの長鎖思考モデル (Guo et al., 2025; DeepSeek-R1 など) は、追加の教師あり学習や強化学習を通じて Test-time Compute のスケーリング (Yao et al., 2024; Guan et al., 2025) を実現し、言語モデルが改善された性能のために最適解を選択できるようにした (Xiang et al., 2025)。これらの進歩は推論能力を強化してきたが、主に一般的な問題解決を対象としており、専門化された学術レビュータスクに焦点を当てたものではない。我々の *Review-with-Thinking* フレームワークは、ピアレビューに特化してこれらの推論手法を拡張するものである。

2.2 信頼性の高い学術文献評価

近年の研究では、自動科学研究における顕著な進展が実証されている。Chris et al. (2024) は自律的な仮説生成と実験のための AI サイエнтиストを開発している (Langley, 1987; Daniil et al., 2023; Aider AI, 2025; Zonglin et al., 2023; Li et al., 2024c; Hu et al., 2024)。マルチエージェントフレームワーク (Ghafarollahi and Buehler, 2024; Rasal and Hauer, 2024; Su et al., 2024) は協調的科学推論を可能にし、Weng et al. (2025) は LLM ベースのレビューシステムが強化学習を通じて科学的発見を促進できることを示した。しかしながら、これらのシステムは構造化された推論を欠いていることが多く、信頼性の低いフィードバックにつながっている。

2.3 頑健な LLM ベース論文レビュー

近年の研究は、ロールプレイエージェントを用いた生成中心のアプローチ (D'Arcy et al., 2024; Gao et al., 2024; Yu et al., 2024; Weng et al., 2025)、メタレビュー合成 (Santu et al., 2024; Li et al., 2023; Zeng et al., 2024)、バイアス検出メカニズム (Liang et al., 2024; Tyser et al., 2024; Tan et al., 2024b) を網羅している。ハイブリッドワークフロー (Jin et al., 2024b; Zyska et al., 2023) は人間と AI の協調と反復改善を統合する。評価ベンチマーク (Funkquist et al., 2022; Zhou et al., 2024b; Kang et al., 2018) や倫理的な分析 (Ye et al., 2024; Latona et al., 2024) がこの分野を進展さ

せてきたが、既存システムは複雑な評価に苦慮し、敵対的攻撃に対して脆弱であり続け、明示的な推論過程の必要性を強調している。

3. データ収集 (Data Collection)

我々は、論文レビューに固有の中間的な推論過程を捕捉する学習データセット **DeepReview-13K** を提示する。これは、論文レビュータスクにおける根本的な課題に3つの側面から取り組むものである：高品質かつ構造化されたレビューデータセットの不足、標準化された評価フレームワークの必要性、そして DeepReview-Bench ベンチマークの構築である。

3.1 DeepReview-13K データセット

このデータセットの統計を表1に示す。最初に OpenReview プラットフォームと arXiv リポジトリからデータを収集し、ICLR カンファレンス 2024 と 2025 の2つのサイクルにわたる 18,976 件の論文投稿を収集した¹。MinerU ツール (Wang et al., 2024a) を用いて論文を解析可能な Markdown 形式に変換し、arXiv から入手可能な場合は LaTeX ソースコードを優先した。各論文について、3つの主要要素からなるレビューセット R を組み立てた：(1) テキスト評価 (強み、弱み、質問)、(2) 反論フェーズからの対話的議論、(3) 標準化されたスコア (全体評価値 [1, 10] と Soundness、Presentation、Contribution の詳細評価 [1, 4])。さらに、メタレビューテキスト、最終評価値、受理決定を収集した。最終的な *DeepReview-13K* データセットは、表1に示すように 13,378 件の有効サンプルから成り、レビュー推論連鎖の構築基盤となっている。

¹ 空の PDF は変換時に除外した。

表 1: データセット統計。Tokens、Rating、AcceptRate の平均値を示す。

データセット	サンプル数	平均トークン数	平均評価値	受理率
ICLR 2024 (Train)	4,131	10,439	5.34	37.8%
ICLR 2025 (Train)	9,247	10,062	5.13	31.2%
DeepReview-13K	13,378	10,178	5.18	33.24%
ICLR 2024 (Test)	652	10,681	5.47	43.7%
ICLR 2025 (Test)	634	10,241	5.18	31.1%
DeepReview-Bench	1,286	10,464	5.33	37.49%

3.2 DeepReview-Test

性能を評価するため、データセットからランダムに 10% (1.2K サンプル) を抽出して *DeepReview-Bench* を作成した。

4. 手法 (Methodology)

複雑な推論手法の最近の進歩 (Xiang et al., 2025; Hao et al., 2024) に着想を得て、レビュー過程を次の3つの主要ステップに分解する深い思考評価フレームワークを提案する：(1) 新規性の検証 (novelty verification) z_1 — 文献レビューによる研究の独自性の評価、(2) 多次元評価 z_2 — 複数の専門家の視点からの洞察の統合、(3) 信頼性検証 z_3 — 内部一貫性と論理的整合性の検証。

4.1 タスク定義

形式的には、入力論文 q が与えられたとき、レビュー対 (s, a) を生成することが目標である。ここで s は定性評価テキスト (メタレビュー) を、 a は定量評価値を表す。我々は推論過程を次のように表す：

$$q \rightarrow z_1 \rightarrow z_2 \rightarrow z_3 \rightarrow (s, a)$$

レビュースコア生成を、逐次推論連鎖にわたる周辺化として定式化する：

$$p(a \mid q) \propto \int p(a \mid z_{1:3}, q) \prod_{t=1}^3 p(z_t \mid z_{1:t-1}, q)$$

ここで、chain-of-thought 項 $\prod_{t=1}^3 p(z_t \mid z_{1:t-1}, q)$ は可能なすべての中間状態系列 $(s_1, \dots, s_n)$ を表す。この構造化アプローチは評価過程の信頼性向上を目的とする。

4.2 構造化推論プロセス

完全な推論経路 (z_1, z_2, z_3) を捕捉する高品質な教師ありファインチューニングデータセットを生成するために特別に設計された、包括的な自動データ構築パイプラインを提示する。

ステージ 1: 新規性検証 (z_1)

新規性検証フレームワークは、質問生成、論文分析、文献レビューの3つの主要要素からなる。まず、論文に基づき Qwen-2.5-72B-Instruct モデル (Qwen et al., 2025) を用いて、研究ギャップ、革新的な方向性、方法論的ブレークスルーに焦点を当てた3つの重要な研究質問を生成する。さらに徹底的な理解を保証するため、Gemini-2.0-Flash-thinking モデルを使用して、特定に設計されたシステムプロンプト (図 6 を参照) に従い、研究動機、コアアイデア、技術的アプローチ、実験設計にわたる体系的な論文分析を実施する。次に、文献検索、比較、要約を OpenScholar (Asai et al., 2024) 上に構築してこれらの研究質問に取り組む。Qwen-2.5-3B-Instruct を few-shot 学習により活用し、質問を Semantic Scholar API を介して検索キーワードに変換して約 60 件の関連論文を取得する。続いて ReRank モデルが取得した論文を再順位付けし、上位 10 件の最も関連性の高い論文を選択し、その内部 QA モデルがレビュー R で引用された文献を含めた包括的なレポートを新規性分析 z_1 として生成する。

ステージ 2: 多次元レビュー (z_2)

建設的なレビューを提供するため、著者の反論を有益な提案に変換しつつ、複数のレビュー R を包括的な視点に統合する。具体的には、Qwen-2.5-72B-Instruct を用いて、各レビューを対応する著者応答とともに分析し、反論から実験結果、理論的証明、実装の詳細を捕捉して、批判を具体的な技術提案に変換するレビュー再構築パイプラインを開発する。再構築過程 (z_2) は次の3原則に従う：(1) 技術的深度の維持、(2) 実行可能なフィードバックの確保、(3) 専門的なトーンと元の引用の保持。

ステージ 3: 信頼性検証 (z_3)

系統的な証拠分析を通じて評価精度を保証するため、Gemini-2-Flash-thinking を用いて、4段階の検証チェーン（方法論の検証、実験的検証、総合的分析）に従い系統的な証拠分析を実施する。各レビューコメントには論文からの裏付けとなる証拠が必要とされ、信頼度レベルが割り当てられる。最後に、Qwen を利用して、元のメタレビュー、レビューアーコメント、検証結果を統合することで新たな meta-review を生成する。このステップは、証拠に基づく分析と建設的な提案を提供しながら、主要な弱点を特定するものである。

品質管理メカニズム：合成された *DeepReview-13K* データセットの高品質を保証するため、Qwen-2.5-72B-Instruct を用いた厳格な自動品質管理プロセスを実装した。このプロセスでは、各生成サンプルを多面的に評価する。具体的には、Qwen-2.5-72B-Instruct に次の2項目を検査

させた：(1) 論理的整合性 — 推論連鎖 (z_1, z_2, z_3) と最終評価 (s, a) が論理的に整合し、矛盾していないかの検証、(2) 完全性 — 構造化データ形式内の空のフィールドや欠落の有無の確認、推論経路と評価のすべての構成要素が存在することの確認。これらのチェックのいずれかに失敗したサンプル（論理的矛盾、不完全、または我々の品質基準を満たさない）は自動的にフラグ付けされ、データセットから除去された。

4.3 モデル学習

DeepReview-13K データセットを用いて、Phi-4 14B (Abdin et al., 2024) を基盤としてモデルを学習した。学習プロセスは 8 基の H100 80G GPU 上で DeepSpeed+ZeRO3 (Rajbhandari et al., 2020; Rasley et al., 2020) を用いて最適化した。特筆すべきは、LongRoPE (Ding et al., 2024) を用いてコンテキストウィンドウを 256K に拡張した点である（学習中は完全なパラメータファインチューニングのため 40K のコンテキストウィンドウを使用）。メモリ制約上、既定のコンテキスト長を超えるサンプルはランダムに切り詰めた。モデルはバッチサイズ 16、学習率 $5e-6$ で 23,500 ステップ学習した。

推論戦略： DeepReview-13K データの各サンプルを、推論経路の切り出し (reasoning path cropping) を用いて 3 つのモードに分割した (図 1(c) を参照)。これにより、要件に応じてテスト時に効率を調整できる。Fast モードは最終評価結果と総合分析レポート (s, a) を直接生成し、中間推論ステップを迂回することで計算コストを最小化する。Standard モードは z_2 と z_3 を含む主要評価ステップを実行し、効率を高く保ちながら評価品質を確保する。Best モードは完全な推論連鎖 (z_1, z_2, z_3) を実装し、新規性検証、多次元評価、信頼性検証、総合分析生成を含む。推論時の新規性検証では、ステージ 1 (セクション 4.2) と同様に、Semantic Scholar API と OpenScholar を用いて文献レビューと分析を通じて研究の新規性と引用の正確性を評価する。3 つのモードはすべて同じモデルアーキテクチャを共有し、実行する評価ステップのみが異なる。これにより、学習済み DeepReview-14B モデルは入力命令によって異なる推論経路を推論時に実行できる。

5. 実験 (Experiments)

5.1 実験設定

ベースライン：2種類のベースラインを検討する。(1) プロンプトベースのベースライン – さまざまなバックボーンモデル（GPT-o1-2024-12-17、Claude-3.5-sonnet-20241022、Gemini-2.0-Flash-Thinking-01-21、DeepSeek-V3、DeepSeek-R1）で実装された AI Scientist（Chris et al., 2024）と AgentReview（Jin et al., 2024a）を含む。(2) ファインチューニング済みのベースライン – ICLR 2024 のレビューデータセットで学習された CycleReviewer-8B と CycleReviewer-70B を含む。推論では、温度パラメータ 0.4、最大入力および出力長をそれぞれ 100K および 16,384 トークンに設定し、完全なテキスト処理を保証する。

5.2 主な結果

テスト結果を表 2 に示す。プロンプトベースベースラインと比較すると、DeepReviewer は AI Scientist からの Rating MSE を平均 65.83% 削減し、Decision Accuracy を平均 15.2 ポイント向上させている。強力なファインチューニング済みベースライン CycleReviewer-70B と比較すると、Rating MSE が 44.80% 削減される。

重要な accept/reject 決定タスクにおいて、DeepReviewer は ICLR 2024 で 64.06% の決定精度と 0.6307 の F1 スコアを達成し、すべてのベースラインを大幅に上回る。特筆すべきは、14B パラメータの DeepReviewer が、CycleReviewer-70B（70B パラメータ）や他のクローズドソース LLM を含む、はるかに大きなモデルよりも優れた性能を示すことであり、DeepReviewer が他のアプローチよりも信頼性の高い論文評価を提供することを実証している。

DeepReviewer は ICLR 2024 と ICLR 2025 でそれぞれ 0.3559 と 0.4047 の Rating Spearman 相関係数を達成しており、CycleReviewer-70B を 6.04%、AI Scientist（DeepSeek-R1）を 25.02% 上回っている。論文選択タスクでは、ICLR 2024 と ICLR 2025 でそれぞれ 0.62 と 0.64 のペアワイズ精度を示し、優れた識別能力を示している。

表 2: DeepReview-13K データセット上でのレビューアーモデルの性能比較。指標は Score（Rating MSE、Rating MAE、Decision Accuracy、Decision F1）、Ranking（Rating Spearman）、Selection（Pairwise Rating Accuracy）に分類される。

手法	モデル	ICLR 2024 — Score				Ranking	Selecti on	ICLR 2025 — Score				Ranking	Selecti on
		R.MS E ↓	R.MA E ↓	D.Acc ↑	D.F1 ↑			R.MS E ↓	R.MA E ↓	D.Acc ↑	D.F1 ↑		
AgentReview	Claude-3.5-sonnet	2.888	1.272	0.433	0.394	0.156	0.553	2.841	1.299	0.283	0.254	-0.022	0.543
	Gemini-2.0-F-Thinking	3.194	1.342	0.440	0.432	-0.025	0.504	2.619	1.217	0.424	0.424	0.097	0.550
	DeepSeek-V3	1.948	1.074	0.411	0.340	0.354	0.610	1.995	1.102	0.314	0.251	0.120	0.570
	GPT-o1	4.341	1.729	0.450	0.442	0.262	0.588	4.307	1.792	0.417	0.416	0.299	0.632
AI Scientist	Claude-3.5-sonnet	3.445	1.504	0.479	0.451	0.037	0.531	3.099	1.350	0.558	0.444	-0.022	0.517
	Gemini-2.0-F-Thinking	4.930	1.871	0.574	0.520	0.075	0.534	3.923	1.647	0.614	0.481	0.257	0.604
	DeepSeek-V3	4.734	1.789	0.560	0.548	0.231	0.584	4.801	1.840	0.406	0.399	0.078	0.547
	DeepSeek-R1	4.165	1.653	0.525	0.499	0.326	0.621	4.772	1.810	0.426	0.416	0.324	0.629
	CycleReviewer 8B	2.891	1.237	0.635	0.553	0.280	0.599	2.446	1.206	0.678	0.559	0.279	0.596
CycleReviewer	70B	2.487	1.251	0.630	0.570	0.336	0.616	2.429	1.213	0.678	0.574	0.267	0.593
DeepReviewer	14B	1.314	0.910	0.641	0.631	0.356	0.624	1.341	0.924	0.688	0.623	0.405	0.640

表 3: 深層評価次元におけるレビューアーモデルの性能比較。Soundness (S.)、Presentation (P.)、Contribution (C.) の3つの評価軸にわたる ICLR 2024 / 2025 の性能を示す。

手法	モデル	Score						Ranking (Spearman ↑)			Pairwise Acc ↑		
		S.MS E ↓	S.MA E ↓	P.MS E ↓	P.MA E ↓	C.MS E ↓	C.MA E ↓	S.	P.	C.	S.	P.	C.
ICLR 2024													
AI Scientist	GPT-o1	0.459	0.534	0.548	0.598	0.755	0.715	0.187	0.072	0.110	0.580	0.541	0.562
	Claude-3.5-sonnet	0.305	0.439	0.475	0.550	1.142	0.888	0.169	0.018	0.028	0.602	0.544	0.573
	Gemini-2.0-F-T	0.723	0.622	0.526	0.580	0.904	0.748	0.105	0.156	0.027	0.585	0.593	0.547
	DeepSeek-V3	0.881	0.772	0.766	0.715	1.694	1.140	0.226	0.319	0.157	0.603	0.624	0.593
	DeepSeek-R1	1.054	0.863	0.536	0.575	1.956	1.297	0.166	0.293	0.301	0.609	0.632	0.652
CycleReviewer	8B	0.252	0.392	0.236	0.369	0.251	0.394	0.199	0.332	0.259	0.577	0.610	0.592
	70B	0.238	0.390	0.241	0.374	0.266	0.405	0.232	0.337	0.235	0.583	0.623	0.590
DeepReviewer	14B	0.158	0.303	0.190	0.329	0.217	0.368	0.320	0.378	0.334	0.618	0.635	0.621
ICLR 2025													
AI Scientist	GPT-o1	0.451	0.550	0.488	0.575	0.673	0.680	-0.039	-0.284	0.167	0.554	0.543	0.597
	Claude-3.5-Sonnet	0.457	0.528	0.580	0.635	0.825	0.763	-0.081	-0.079	-0.005	0.554	0.527	0.545
	Gemini-2.0-F-T	0.428	0.522	0.634	0.611	0.570	0.588	0.357	0.059	0.277	0.654	0.550	0.632
	DeepSeek-V3	0.800	0.741	0.912	0.766	2.018	1.259	0.193	0.062	-0.068	0.601	0.568	0.532
	DeepSeek-R1	0.858	0.764	0.488	0.559	2.162	1.375	0.313	0.313	0.306	0.629	0.599	0.627
CycleReviewer	8B	0.262	0.393	0.288	0.421	0.267	0.411	0.238	0.250	0.251	0.591	0.607	0.592
	70B	0.259	0.400	0.256	0.400	0.260	0.403	0.232	0.277	0.191	0.587	0.605	0.578
DeepReviewer	14B	0.224	0.365	0.218	0.366	0.263	0.410	0.381	0.370	0.324	0.606	0.638	0.622

表 3 は Soundness、Presentation、Contribution の 3 つの重要次元についての詳細な分析を示す。ICLR 2024 での Soundness 評価について、DeepReviewer-14B は 0.1578 の MSE と 0.3029 の MAE を達成し、CycleReviewer-70B に対する改善がそれぞれ 33.58% と 22.09% に及ぶ。DeepReviewer

は Contribution と Soundness 精度で AI Scientist (Gemini-2.0-Flash-Thinking) をやや下回るものの、すべての次元でバランスの取れた強力な性能を維持している。

細粒度評価能力と全体評価性能との間に強い相関が観察される。DeepReviewer や Claude-3.5-Sonnet のような次元別評価に長けたモデルは、全体評価においても優れた性能を一貫して示す。このパターンは、我々の多段階推論連鎖設計、特にフレームワークにおける多面的評価の必要性を検証するものである。

5.3 レビューテキストの品質

表 4 は、すべての評価次元における DeepReviewer の圧倒的な優位性を示している。AI Scientist (Gemini-2.0-Flash-Thinking) との比較では、Gemini を判定として用いているにもかかわらず、Gemini はほとんどのレビューを DeepReviewer 優位と判定した (建設的価値と分析的深度で 53.47% 勝利)。技術精度の 1 次元のみが Gemini 自身のレビューを優位とした (20.79%)。この自己批判的な評価は、評価フレームワークの客観性をさらに検証している。総合判定において、DeepReviewer は ICLR 2024 で AI Scientist (GPT-o1) に対し 88.21%、AgentReview (GPT-4o) に対し 98.15% という顕著な勝率を達成している。優位性は建設的価値と分析的深度で最も顕著である。AgentReview (GPT-4o) との比較では、DeepReviewer はそれぞれ 99.02% と 99.01% の勝率を達成しており、思考を伴う DeepReview フレームワークがより洞察に富む分析と実行可能な提案を生成することを示している。

表 4: 一般的な整合性タスクにおける DeepReviewer とベースラインの直接比較。Win は Gemini-2.0-Flash-Thinking が DeepReviewer の応答をベースラインより優れていると評価したことを示す。ライトグレーのセルは勝者のベースラインを示す。

ベースライン	比較項目	建設的価値		分析的深度		妥当性		技術精度		総合判定	
		Win ↑	Lose	Win ↑	Lose	Win ↑	Lose	Win ↑	Lose	Win ↑	Lose
ICLR 2024											
AI Scientist GPT-o1	vs. の勝率	89.80	6.67	87.67	6.67	51.69	3.53	25.12	11.67	88.21	6.63
AI Scientist Claude-3.5-Sonnet	vs. の勝率	96.88	3.12	97.92	2.08	80.21	4.17	77.08	2.08	95.74	4.26
AI Scientist Gemini-2.0-F-T	vs. の勝率	53.47	17.82	53.47	20.79	24.75	10.89	18.81	20.79	59.41	25.74
AI Scientist DeepSeek-V3	vs. の勝率	96.04	1.98	99.01	0.00	72.28	0.99	67.33	4.95	96.22	0.00
AI Scientist DeepSeek-R1	vs. の勝率	89.22	7.84	74.51	13.73	45.10	5.88	26.47	18.63	80.20	16.83
AgentReview Claude-3.5-Sonnet	vs. の勝率	96.84	1.05	98.94	0.00	90.43	0.00	77.08	0.00	98.90	0.00
AgentReview GPT-4o	vs. の勝率	99.02	0.99	99.01	0.99	95.05	0.99	61.76	4.90	98.15	1.00
CycleReviewer 8B	vs. の勝率	97.30	1.80	98.20	0.91	90.92	0.91	87.50	0.00	96.09	0.91
CycleReviewer 70B	vs. の勝率	98.33	1.11	98.89	0.01	92.78	0.01	79.44	0.01	98.33	1.11
ICLR 2025											
AI Scientist GPT-o1	vs. の勝率	91.67	8.33	89.58	8.33	60.42	4.17	37.50	8.33	91.67	8.33
AI Scientist Claude-3.5-Sonnet	vs. の勝率	97.87	1.06	100.00	0.00	92.55	1.06	65.96	0.00	98.94	1.06
AI Scientist DeepSeek-R1	vs. の勝率	89.29	6.25	81.25	10.71	51.79	5.36	26.79	18.75	87.39	9.01
AgentReview Claude-3.5-Sonnet	vs. の勝率	95.74	1.06	97.85	2.15	90.32	2.15	74.74	1.05	97.83	2.17
AgentReview GPT-4o	vs. の勝率	95.28	2.09	95.37	1.40	92.10	0.85	65.03	5.47	94.15	2.39
CycleReviewer 8B	vs. の勝率	98.45	1.55	98.24	1.89	86.37	0.77	86.36	2.27	98.45	1.55
CycleReviewer 70B	vs. の勝率	96.17	1.64	96.17	2.19	86.34	1.64	72.68	3.28	96.72	1.64

5.4 攻撃防御分析 (Defending Against Adversarial Attacks)

敵対的命を論文に挿入することで、DeepReviewer の adversarial attack に対する頑健性を評価する (Ye et al., 2024)。図 2 は通常時と攻撃時における異なる次元の評価値比較を示している。敵対的サンプルで具体的に訓練していないにもかかわらず、DeepReviewer モデルはベースラインシステムと比較して優れた頑健性を示している。攻撃時、DeepReviewer の全体評価値増加はわずか 0.31 ポイント (5.38 から 5.69) であり、他のシステムは大きな脆弱性を示す。例えば、Gemini-2.0-Flash-Thinking は 4.26 ポイント (4.23 から 8.49) もの劇的な増加を示し、DeepSeek-V3 は 1.41 の増加 (6.76 から 8.17) を示した。このパターンは細粒度の次元でも一貫していた。例えば、DeepReviewer の Soundness スコアはわずか 0.12 ポイントの増加であったが、Claude-3.5-Sonnet (1.10) と Gemini-2.0-Flash-Thinking (1.38) はより大きな増加を示した。この頑健性は、直接的な入出力モデルとは異なり、内容理解、新規性検証、信頼性チェックを含む DeepReviewer の多段階推論フレームワークに起因すると考えられる。しかし、攻撃下でのわずかなスコア増加は改善の余地を示唆しており、訓練中に敵対的サンプルを組み込むことを推奨する。

5.5 テスト時スケーラビリティの検討 (Test-Time Scaling)

DeepReviewer モデルは、入力命令によって制御可能な 2 つの仕組みを通じて独自の Test-Time Scaling 機能を備えている。Reasoning Path Scaling と Reviewer Scaling である。

Reasoning Path Scaling : Fast、Standard、Best の 3 つの推論モードを提供し、徐々に深い推論と対応する出力トークン長約 3,000、8,000、14,500 を提供する。

Reviewer Scaling : Standard モード内で採用され、シミュレーションされたレビュアー数を $R=1$ から $R=6$ に調整する。シミュレーションされたレビュアー間の協調を通じて多視点評価の合成を可能にする。

両スケーリング手法は本質的にモデルの評価過程を拡張する。Reasoning Path Scaling は分析的深度を増すことによって、Reviewer Scaling は協調レビューを模倣することによって。

性能分析 : 図 3 は推論計算量の増加に伴う顕著な性能向上を示している。Reasoning Path Scaling (赤い星印) では、Fast から Best モードへの切り替えにより、すべての指標で着実な改善が得られ、Rating Spearman 相関は 8.97% (0.326 から 0.355) 増加した。Reviewer Scaling (緑の菱印) は様々なタスクで多様なパターンを示す。スコアリングタスク (Decision Accuracy、Rating MSE、Soundness MSE) では、追加レビュアーによる一貫した性能向上が観察され、スコア集約が複数の視点によって強化されることが示されている。 $R=4$ における Reviewer Scaling の性能変動は、おそらくモデルの学習分布が 4 人のレビュアー周辺に集中していることに起因する。多様な結果にもかかわらず、両スケーリング手法は正の傾向を示し、我々のフレームワークが計算資源をより有効活用すること示している。利益は指標によって異なる：スコアリングタスクが最も改善され、次にランキング、選択が続く。これは多段階推論が複雑な論文評価に優れていることを示唆しており、2 つの論文を選ぶような単純な比較では追加推論の恩恵が小さいことを示唆している。

DeepReviewer の Fast モードが出力トークン数が半分 (3,000) でありながら、CycleReviewer モデル (6,000 出力トークン) を Decision Accuracy、Rating MSE、Soundness、Presentation、

Contribution の Spearman 相関を含む様々な指標で上回ったことは注目に値する。簡略化された推論経路にもかかわらず、Fast モードは主要な論文内容と重大な欠陥の特定などの中核的評価ロジックを維持する。DeepReviewer がより少ない出力トークンで高い性能を達成し、最も重要な情報に焦点を当てていることが示された。これらの変動にもかかわらず、両スケーリングアプローチは指標全体で正の傾向を示し、増加する計算投資が、より洗練された推論モードや追加のシミュレーションレビューアーによってモデルの論文評価能力を強化することを検証している。

6. 結論 (Conclusions)

本研究では、研究論文評価のための新しいフレームワーク *DeepReviewer* を提案した。これは、論文レビューにおける LLM の信頼性向上を目的とするものである。*DeepReviewer* は Test-Time Scaling を通じて多様なニーズに対応する適応可能な推論深度を達成する。我々の貢献は3つある：(1) 体系的かつ深い論文評価のための学習を容易にする、詳細にアノテーションされたデータセット *DeepReview-13K* の作成、(2) *DeepReviewer* モデルの学習、(3) 客観的評価と主観的評価の両方における *DeepReviewer* の優位性に関する包括的な検証。特筆すべきは、Reasoning Path Scaling と Reviewer Scaling 戦略を通じた効果的な Test-Time Scaling を探索し、実証したことである。さらに、*DeepReviewer* の敵対的攻撃に対する強い耐性を実証した。これは、明示的なロバストネス学習を行っていないにもかかわらず達成されたものであり、構造化アプローチの自動科学的評価への有効性を検証する。

7. 限界 (Limitations)

まず、本アプローチは自動パイプラインを通じて構築された合成データセット *DeepReview-13K* に依存している。専門家のレビュー過程を模倣し品質管理メカニズムを組み込むように綿密に設計されているものの、この合成データは本物の人間による論文レビューの複雑さとニュアンスを完全には捉えられていない可能性がある。我々は ICLR カンファレンスからの実世界のレビューデータを活用し、構造化された推論アノテーションを組み込むことでこれを緩和するよう努めてきたが、合成データの固有の限界は残っている。

次に、DeepReviewer が効率のための Test-Time Scaling を提供する一方で、完全な推論連鎖と外部知識検索を利用する「Best」モードは計算コストが高くなる。これを「Fast」モードと「Standard」モードを提供することで対処し、徹底さと計算コストの間のトレードオフを可能にし、多様なアプリケーション要件に対応する。

さらに、敵対的攻撃に対する頑健性を示したものの、完全な免疫は未だ達成されておらず、セキュリティと信頼性の向上に関する継続的な研究の必要性を示している。これらの限界にもかかわらず、DeepReviewer はより信頼性が高く頑健な LLM ベースの論文レビューシステムに向けた重要な一歩を表しており、頑健な構造化推論の探求は将来の研究の道を開くものである。

8. 倫理的配慮 (Ethical Considerations)

DeepReviewer の開発は、学術的な論文レビューの効率と質を向上させる大きな可能性を秘めているが、本質的に慎重な注意を要する倫理的配慮を伴う。我々は、ピアレビュー過程の自動化がバイアスの増幅、人間レビュアーのスキル低下、透明性と説明責任の潜在的な低下といったリスクを導入することを認識する。具体的には、DeepReviewer は他の LLM と同様に、訓練データ内に存在するバイアスや、そのアーキテクチャ内にコード化されているバイアスを不注意に永続化し、さらには増幅する可能性がある。これにより、過小評価されたグループ、独創的または unconventional な方法論、あるいは主流とは見なされないトピックからの研究に対して、*DeepReview-13K* データセットが代表的かつ公正であるように合成的に生成されたとしても、体系的な不利益が生じる可能性がある。さらに、自動レビュー支援への過度の依存は、人間レビュアーの批判的思考スキルを低下させ、十分な人間の監視なしに AI 駆動評価に依存するようになる deskilling 効果をもたらす可能性がある。

これらの倫理的懸念に先んじて対処し、潜在的な害を緩和するため、我々は DeepReviewer の開発と展開を通じて多面的なアプローチを実施した。第一に、我々の訓練データは合成であるが、*DeepReview-13K* データセットとその生成パイプラインを厳密に設計し、専門家のレビュアー推論を明示的にモデル化し、多様な視点を組み込んで意図しないバイアスの導入を最小限に抑えるよう努めた。第二に、DeepReviewer は決定支援ツールとして意図されており、人間の専門知識を補完するものであり、置き換えるものではないと強調する。我々は、DeepReviewer の出力が専門レビュアーによって批判的に評価され、文脈化される人間参加型 (human-in-the-loop) アプローチを強く推奨する。透明性を確保するため、DeepReviewer をオープンソースリソースとして公開し、そのコード、アーキテクチャ、潜在的なバイアスに対するコミュニティの精査を可能にしている。コード公開に合わせて、自動化された出力への過度の依存に対する注意を明示的に喚起し、人間の監視と批判的評価の重要性を強調する包括的なユーザーガイドラインとベストプラクティスを提供する。さらに、我々のオープンソースライセンスは permissive であるが、ユーザーは DeepReviewer のダウンロード時に所属機関、個人情報、意図されたユースケースを開示することが義務付けられている。この措置は説明責任を育成し、現実のアプリケーションを監視し、ユーザーフィードバックを収集し、モデルとその倫理的セーフガードを反復的に改善するためのフィードバックループを可能にすることを意図している。我々はまた、多様なデータセットとレビューシナリオにわたる DeepReviewer の継続的なバイアス監査とベンチマークに取り組み、その性能を継続的に評価し、改善すべき領域を特定することを約束する。我々は、これらの先見的な措置と進行中のコミュニティエンゲージメントおよび責任あるユーザープラクティスの組み合わせが、潜在的な害を最小限に抑え、科学的ピアレビュー過程における DeepReviewer の倫理的かつ有益な応用を保証するために重要であると確信している。

9. 謝辞 (Acknowledgements)

有益な提案と貴重なフィードバックをいただいたレビュアーの皆様に感謝する。本研究は、中国国家自然科学基金（NSFC）重点プログラム（Grant No. 62336006）および Research Center for Industries of the Future, Westlake University の研究プログラム No. WU2023C020 により支援されている。また、ICLR 2025 における World Model ワークショップの主催者にも謝意を表する。

本文書はユーザー指定の論文（DeepReview, Zhu et al., 2025, ACL 2025）に基づく日本語訳である。図表、表の数値、モデル名、参考文献の書誌情報は原文を保持しつつ、内容の説明を自然な日本語に翻訳した。数式、特殊な図、表内の一部の細かい表記は原文どおり英語のままとしている。

参考文献 (References)

- Marah Abdin, Jyoti Aneja, Harkirat Behl, Sébastien Bubeck, Ronen Eldan, Suriya Gunasekar, Michael Harrison, Russell J. Hewett, Mojan Javaheripi, Piero Kauffmann, James R. Lee, Yin Tat Lee, Yuanzhi Li, Weishung Liu, Caio C. T. Mendes, Anh Nguyen, Eric Price, Gustavo de Rosa, Olli Saarikivi, Adil Salim, Shital Shah, Xin Wang, Rachel Ward, Yue Wu, Dingli Yu, Cyril Zhang, Yi Zhang. 2024. *Phi-4 technical report*. arXiv:2412.08905.
- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altschmidt, Sam Altman, Shyamal Anadkat, et al. 2023. *GPT-4 technical report*. arXiv:2303.08774.
- Aider AI. 2025. *Aider — AI pair programming in your terminal*. <https://github.com/Aider-AI/aider>
- Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, Denny Zhou. 2022. *What learning algorithm is in-context learning? Investigations with linear models*. arXiv:2211.15661.
- Bruce Alberts, Brooks Hanson, Katrina L. Kelner. 2008. *Reviewing peer review*.
- Akari Asai, Jacqueline He, Rulin Shao, Weijia Shi, Amanpreet Singh, Joseph Chee Chang, Kyle Lo, Luca Soldaini, Sergey Feldman, Mike D'arcy, David Wadden, Matt Latzke, Minyang Tian, Pan Ji, Shengyan Liu, Hao Tong, Bohao Wu, Yanyu Xiong, Luke Zettlemoyer, Graham Neubig, Dan Weld, Doug Downey, Wen tau Yih, Pang Wei Koh, Hannaneh Hajishirzi. 2024. *OpenScholar: Synthesizing scientific literature with retrieval-augmented language models*. arXiv:2411.14199.
- Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, et al. 2023. *Qwen technical report*. arXiv:2309.16609.
- ICLR Blog. 2024. *ICLR 2025: Assisting reviewers*. <https://blog.iclr.cc/2024/10/09/iclr2025-assisting-reviewers/>
- Lu Chris, Lu Cong, Lange Robert, Foerster Jakob, Clune Jeff, Ha David. 2024. *The AI Scientist: Towards fully automated open-ended scientific discovery*. arXiv:2408.06292v3.
- Boiko Daniil A., MacKnight Robert, Gomes Gabe. 2023. *Emergent autonomous scientific research capabilities of large language models*. arXiv:2304.05332v1.
- Mike D'Arcy, Tom Hope, Larry Birnbaum, Doug Downey. 2024. *MARG: Multi-agent review generation for scientific papers*. arXiv:2401.04259.
- Yiran Ding, Li Lyna Zhang, Chengruidong Zhang, Yuanyuan Xu, Ning Shang, Jiahang Xu, Fan Yang, Mao Yang. 2024. *LongRoPE: Extending LLM context window beyond 2 million tokens*. ICML.
- Iddo Drori, Dov Te'eni. 2024. *Human-in-the-loop AI reviewing: Feasibility, opportunities, and risks*. Journal of the Association for Information Systems, 25(1):98–109.

- Jiangshu Du, Yibo Wang, Wenting Zhao, Zhongfen Deng, Shuaiqi Liu, Renze Lou, Henry Peng Zou, Pranav Narayanan Venkit, Nan Zhang, Mukund Srinath, Haoran Ranran Zhang, Vipul Gupta, Yinghui Li, Tao Li, Fei Wang, Qin Liu, Tianlin Liu, Pengzhi Gao, Congying Xia, Chen Xing, Cheng Jiayang, Zhaowei Wang, Ying Su, Raj Sanjay Shah, Ruohao Guo, Jing Gu, Haoran Li, Kangda Wei, Zihao Wang, Lu Cheng, Surangika Ranathunga, Meng Fang, Jie Fu, Fei Liu, Ruihong Huang, Eduardo Blanco, Yixin Cao, Rui Zhang, Philip S. Yu, Wenpeng Yin. 2024. *LLMs assist NLP researchers: Critique paper (meta-)reviewing*. EMNLP, pp. 5081–5099.
- Martin Funkquist, Ilia Kuznetsov, Yufang Hou, Iryna Gurevych. 2022. *CiteBench: A benchmark for scientific citation text generation*. arXiv:2212.09577.
- Zhaolin Gao, Kianté Brantley, Thorsten Joachims. 2024. *Reviewer2: Optimizing review generation through prompt generation*. arXiv:2402.10886.
- Alireza Ghafarollahi, Markus J. Buehler. 2024. *SciAgents: Automating scientific discovery through multi-agent intelligent graph reasoning*. arXiv:2409.05556.
- Xinyu Guan, Li Lina Zhang, Yifei Liu, Ning Shang, Youran Sun, Yi Zhu, Fan Yang, Mao Yang. 2025. *rStar-Math: Small LLMs can master math reasoning with self-evolved deep thinking*. arXiv:2501.04519.
- Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. 2025. *DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning*. arXiv:2501.12948.
- Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, Yuandong Tian. 2024. *Training large language models to reason in a continuous latent space*. arXiv:2412.06769.
- Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, Jacob Steinhardt. 2021. *Measuring mathematical problem solving with the MATH dataset*. NeurIPS.
- Xiang Hu, Hongyu Fu, Jing Wang, Yifeng Wang, Zhikun Li, Renjun Xu, Yu Lu, Yaochu Jin, Lili Pan, Zhenzhong Lan. 2024. *Nova: An iterative planning and search approach to enhance novelty and diversity of LLM-generated ideas*. arXiv:2410.14255.
- Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helyar, Aleksander Madry, Alex Beutel, Alex Carney, et al. 2024. *OpenAI o1 System Card*. arXiv:2412.16720.
- Ziwei Ji, Tiezheng Yu, Yan Xu, Nayeon Lee, Etsuko Ishii, Pascale Fung. 2023. *Towards mitigating LLM hallucination via self reflection*. EMNLP Findings, pp. 1827–1843.
- Yiqiao Jin, Qinlin Zhao, Yiyang Wang, Hao Chen, Kaijie Zhu, Yijia Xiao, Jindong Wang. 2024a/b. *AgentReview: Exploring peer review dynamics with LLM agents*. arXiv:2406.12708.
- Dongyeop Kang, Waleed Ammar, Bhavana Dalvi, Madeleine Van Zuylen, Sebastian Kohlmeier, Eduard Hovy, Roy Schwartz. 2018. *A dataset of peer reviews (PeerRead): Collection, insights and NLP applications*. arXiv:1804.09635.
- P. Langley. 1987. *Scientific Discovery: Computational Explorations of the Creative Processes*. MIT Press.
- Giuseppe Russo Latona, Manoel Horta Ribeiro, Tim R Davidson, Veniamin Veselovsky, Robert West. 2024. *The AI review lottery: Widespread AI-assisted peer reviews boost paper scores and acceptance rates*. arXiv:2405.02150.
- Dawei Li, Bohan Jiang, Liangjie Huang, Alimohammad Beigi, Chengshuai Zhao, Zhen Tan, Amrita Bhattacharjee, Yuxuan Jiang, Canyu Chen, Tianhao Wu, Kai Shu, Lu Cheng, Huan Liu. 2024a. *From generation to judgment: Opportunities and challenges of LLM-as-a-judge*. arXiv:2411.16594.

- Miao Li, Eduard Hovy, Jey Han Lau. 2023. *Summarizing multiple documents with conversational structure for meta-review generation*. arXiv:2305.01498.
- Michael Y. Li, Emily Fox, Noah Goodman. 2024b. *Automated statistical model discovery with language models*. ICML.
- Ziyue Li, Yuan Chang, Xiaoqiu Le. 2024c. *Simulating expert discussions with multi-agent for enhanced scientific problem solving*. SDP Workshop, ACL, pp. 243–256.
- Weixin Liang, Zachary Izzo, Yaohui Zhang, Haley Lepp, Hancheng Cao, Xuandong Zhao, Lingjiao Chen, Haotian Ye, Sheng Liu, Zhi Huang, et al. 2024. *Monitoring AI-modified content at scale: A case study on the impact of ChatGPT on AI conference peer reviews*. arXiv:2403.07183.
- Chin-Yew Lin. 2004. *ROUGE: A package for automatic evaluation of summaries*. Text Summarization Branches Out, ACL, pp. 74–81.
- Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, et al. 2024. *Self-Refine: Iterative refinement with self-feedback*. NeurIPS 36.
- Maxwell Nye, Anders Johan Andreassen, Guy Gur-Ari, Henryk Michalewski, Jacob Austin, David Bieber, David Dohan, Aitor Lewkowycz, Maarten Bosma, David Luan, et al. 2021. *Show your work: Scratchpads for intermediate computation with language models*. arXiv:2112.00114.
- Kishore Papineni, Salim Roukos, Todd Ward, Wei-Jing Zhu. 2002. *BLEU: A method for automatic evaluation of machine translation*. ACL, pp. 311–318.
- Qwen Team: An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, Huan Lin, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Yang, Jiaxi Yang, Jingren Zhou, Junyang Lin, Kai Dang, Keming Lu, Keqin Bao, Kexin Yang, Le Yu, Mei Li, Mingfeng Xue, Pei Zhang, Qin Zhu, Rui Men, Runji Lin, Tianhao Li, Tianyi Tang, Tingyu Xia, Xingzhang Ren, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yu Wan, Yuqiong Liu, Zeyu Cui, Zhenru Zhang, Zihan Qiu. 2025. *Qwen2.5 Technical Report*. arXiv:2412.15115.
- Samyam Rajbhandari, Jeff Rasley, Olatunji Ruwase, Yuxiong He. 2020. *ZeRO: Memory optimizations toward training trillion parameter models*. arXiv:1910.02054.
- Sumedh Rasal, EJ Hauer. 2024. *Navigating complexity: Orchestrated problem solving with multi-agent LLMs*. arXiv:2402.16713.
- Jeff Rasley, Samyam Rajbhandari, Olatunji Ruwase, Yuxiong He. 2020. *DeepSpeed: System optimizations enable training deep learning models with over 100 billion parameters*. KDD '20, pp. 3505–3506.
- Bedemariam Rewina, Perez Natalie, Bhaduri Sreyoshi, Kapoor Satya, Gil Alex, Conjar Elizabeth, Itoku Ikkei, Theil David, Chadha Aman, Nayyar Naumaan. 2025. *Potential and perils of large language models as judges of unstructured textual data*. arXiv:2501.08167v2.
- Shubhra Kanti Karmaker Santu, Sanjeev Kumar Sinha, Naman Bansal, Alex Knipper, Souvika Sarkar, John Salvador, Yash Mahajan, Sri Guttikonda, Mousumi Akter, Matthew Freestone, et al. 2024. *Prompting LLMs to compose meta-review drafts from peer-review narratives of scholarly manuscripts*. arXiv:2402.15589.
- Dmitry Scherbakov, Nina Hubig, Vinita Jansari, Alexander Bakumenko, Leslie A. Lenert. 2024. *The emergence of large language models (LLMs) as a tool in literature reviews: An LLM automated systematic review*. arXiv:2409.04600.

- Laurie A. Schintler, Connie L. McNeely, James Witte. 2023. *A critical examination of the ethics of AI-mediated peer review*. arXiv:2309.12356.
- Chenglei Si, Diyi Yang, Tatsunori Hashimoto. 2025. *Can LLMs generate novel research ideas? A large-scale human study with 100+ NLP researchers*. ICLR.
- Haoyang Su, Renqi Chen, Shixiang Tang, Xinzhe Zheng, Jingzhe Li, Zhenfei Yin, Wanli Ouyang, Nanqing Dong. 2024. *Two heads are better than one: A multi-agent system has the potential to improve scientific idea generation*. arXiv:2410.09403.
- Saha Swarnadeep, Li Xian, Ghazvininejad Marjan, Weston Jason, Wang Tianlu. 2025. *Learning to plan & reason for evaluation with thinking-LLM-as-a-judge*. arXiv:2501.18099v1.
- Cheng Tan, Dongxin Lyu, Siyuan Li, Zhangyang Gao, Jingxuan Wei, Siqi Ma, Zicheng Liu, Stan Z. Li. 2024a/b. *Peer review as a multi-turn and long-context dialogue with role-based interactions*. arXiv:2406.05688.
- Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. 2023. *LLaMA: Open and efficient foundation language models*. arXiv:2302.13971.
- Keith Tyser, Ben Segev, Gaston Longhitano, Xin-Yu Zhang, Zachary Meeks, Jason Lee, Uday Garg, Nicholas Belsten, Avi Shporer, Madeleine Udell, et al. 2024. *AI-driven review systems: Evaluating LLMs in scalable and bias-aware academic reviews*. arXiv:2408.10365.
- Bin Wang, Chao Xu, Xiaomeng Zhao, Linke Ouyang, Fan Wu, Zhiyuan Zhao, Rui Xu, Kaiwen Liu, Yuan Qu, Fukai Shang, Bo Zhang, Liqun Wei, Zhihao Sui, Wei Li, Botian Shi, Yu Qiao, Dahua Lin, Conghui He. 2024a. *MinerU: An open-source solution for precise document content extraction*. arXiv:2409.18839.
- Qingyun Wang, Qi Zeng, Lifu Huang, Kevin Knight, Heng Ji, Nazneen Fatema Rajani. 2020. *ReviewRobot: Explainable paper review generation based on knowledge synthesis*. INLG, pp. 384–397.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc V Le, Ed H Chi, Sharan Narang, Aakanksha Chowdhery, Denny Zhou. 2023. *Self-consistency improves chain of thought reasoning in language models*. ICLR.
- Yidong Wang, Zhuohao Yu, Wenjin Yao, Zhengran Zeng, Linyi Yang, Cunxiang Wang, Hao Chen, Chaoya Jiang, Rui Xie, Jindong Wang, Xing Xie, Wei Ye, Shikun Zhang, Yue Zhang. 2024b. *PandaLM: An automatic evaluation benchmark for LLM instruction tuning optimization*. ICLR.
- Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed H Chi, Quoc V Le, Denny Zhou, et al. 2022. *Chain-of-thought prompting elicits reasoning in large language models*. NeurIPS.
- Yixuan Weng, Shizhu He, Kang Liu, Shengping Liu, Jun Zhao. 2024. *ControlLM: Crafting diverse personalities for language models*. arXiv:2402.10151.
- Yixuan Weng, Minjun Zhu, Guangsheng Bao, Hongbo Zhang, Jindong Wang, Yue Zhang, Linyi Yang. 2025. *CycleResearcher: Improving automated research via automated review*. ICLR.
- Yixuan Weng, Minjun Zhu, Fei Xia, Bin Li, Shizhu He, Shengping Liu, Bin Sun, Kang Liu, Jun Zhao. 2023. *Large language models are better reasoners with self-verification*. EMNLP.

- Violet Xiang, Charlie Snell, Kanishk Gandhi, Alon Albalak, Anikait Singh, Chase Blagden, Duy Phung, Rafael Rafailov, Nathan Lile, Dakota Mahan, Louis Castricato, Jan-Philipp Franken, Nick Haber, Chelsea Finn. 2025. *Towards system 2 reasoning in LLMs: Learning how to think with meta chain-of-thought*. arXiv:2501.04682.
- Shunyu Yao, Dian Yu, Jeffrey Zhao, Izhak Shafran, Tom Griffiths, Yuan Cao, Karthik Narasimhan. 2024. *Tree of Thoughts: Deliberate problem solving with large language models*. NeurIPS 36.
- Rui Ye, Xianghe Pang, Jingyi Chai, Jiaao Chen, Zhenfei Yin, Zhen Xiang, Xiaowen Dong, Jing Shao, Siheng Chen. 2024. *Are we there yet? Revealing the risks of utilizing large language models in scholarly peer review*. arXiv:2412.01708.
- Jianxiang Yu, Zichen Ding, Jiaqi Tan, Kangyang Luo, Zhenmin Weng, Chenghua Gong, Long Zeng, Renjing Cui, Chengcheng Han, Qiushi Sun, et al. 2024. *Automated peer reviewing in paper sea: Standardization, evaluation, and analysis*. arXiv:2407.12857.
- Weizhe Yuan, Pengfei Liu, Graham Neubig. 2021. *Can we automate scientific reviewing?* arXiv:2102.00176.
- Qi Zeng, Mankeerat Sidhu, Hou Pong Chan, Lu Wang, Heng Ji. 2024. *Scientific opinion summarization: Paper meta-review generation dataset, methods, and evaluation*. AI4Research Workshop.
- Ruiyang Zhou, Lu Chen, Kai Yu. 2024a/b. *Is LLM a reliable reviewer? A comprehensive evaluation of LLM on automatic paper reviewing tasks*. LREC-COLING 2024, pp. 9340–9351.
- Minjun Zhu, Yixuan Weng, Linyi Yang, Yue Zhang. 2025. *Personality alignment of large language models*. ICLR.
- Zhenzhen Zhuang, Jiandong Chen, Hongfeng Xu, Yuwen Jiang, Jialiang Lin. 2025. *Large language models for automated scholarly paper review: A survey*. arXiv:2501.10326.
- Yang Zonglin, Du Xinya, Li Junxian, Zheng Jie, Poria Soujanya, Cambria Erik. 2023. *Large language models for automated open-domain scientific hypotheses discovery*. arXiv:2309.02726.
- Dennis Zyska, Nils Dycke, Jan Buchmann, Ilia Kuznetsov, Iryna Gurevych. 2023. *CaRE: Collaborative AI-assisted reading environment*. arXiv:2302.12611.