

個別化された人間フィードバックによる パーソナライズド言語モデリング

Personalized Language Modeling from Personalized Human Feedback

Xinyu Li^{*,1}, Ruiyang Zhou³, Zachary C. Lipton¹, Liu Leqi^{*,2,3}

¹ Carnegie Mellon University (カーネギーメロン大学)

² Princeton Language and Intelligence (プリンストン大学 言語と知能研究所)

³ University of Texas at Austin (テキサス大学オースティン校)

※ 等貢献者。連絡先: xinyul2@andrew.cmu.edu, leqiliu@utexas.edu

キーワード: Reinforcement Learning from Human Feedback (人間フィードバックからの強化学習)・
Personalization (パーソナライゼーション)・Large Language Models (大規模言語モデル)

原論文: arXiv:2402.05133 (cs.CL, 2024年2月)

コード公開先: https://github.com/HumainLab/Personalized_RLHF

目次

要旨Abstract

1 はじめに (Introduction)

2 関連研究 (Related Work)

3 標準RLHF (Vanilla RLHF)

3.1 パーソナライズドRLHFの動機づけ：選好の一様性仮定の問題

4 個別化された人間フィードバックからの学習

4.1 パーソナライズドLLM：問題設定

4.2 P-RLHF一般フレームワーク

4.3 P-RLHFユーザーモデル

4.4 P-RLHF学習目的：Personalized DPO (P-DPO)

5 実験

5.1 相反する選好を持つ生成

5.2 異なる選好プロファイル下での指示追従

5.3 大規模ユーザーベースの実世界選好データセット

6 結論 (Conclusions)

参考

文献References

付録

A 関連研究の追加

付録

D 指示追従実験の詳細

付録

E 実世界データセットの詳細

付録

F P-RLHF目的式の追加詳細

要旨 (Abstract)

パーソナライズド大規模言語モデル (Personalized LLMs) は、応答を個々のユーザーの選好に合わせて調整することを目的としている。人間のフィードバックからの強化学習 (Reinforcement Learning from Human Feedback, RLHF) は LLM を人間の選好に整合させるための汎用的な枠組みとして広く用いられているものの、標準的な RLHF は全ユーザーの選好が同一の分布に従うものと仮定しているため、ユーザーの選好が多様である状況下ではファインチューニング後の LLM が個別化された内容を生成できない。本研究では、軽量のユーザーモデルを用いて個々のユーザーの選好を捕捉し、ユーザーモデルとパーソナライズド LLM を人間のフィードバックから同時に学習する効率的な枠組みである **Personalized-RLHF (P-RLHF)** を提案する。P-RLHF は次の三つの特徴をもつ。第一に、LLM が個別化されたコンテンツを生成可能であり、かつユーザー数が増大しても効率的にスケールできる。第二に、テキスト入力として記述される明示的なユーザー選好と、フィードバックデータに符号化された暗黙的なユーザー選好の双方を扱える。第三に、実世界の場面で取得がしばしば困難な、ユーザーが選好を完全に言語化する必要を不要にする。

実験の結果、P-RLHF を用いて訓練されたパーソナライズド LLM は、個々のユーザーの選好により整合した応答を生成し、異なるタスクを通じて非パーソナライズドの標準 RLHF およびプロンプトベースのパーソナライゼーション手法を上回った。コードは https://github.com/HumainLab/Personalized_RLHF で公開している。

キーワード: Reinforcement Learning from Human Feedback (人間フィードバックからの強化学習) ・ Personalization (パーソナライゼーション) ・ Large Language Models (大規模言語モデル)

1. はじめに (Introduction)

パーソナライゼーションは、ユーザー情報（人口統計学的属性や興味など）や履歴データに基づいて、個々のユーザーの選好に合わせた応答や推薦を生成することを目的とする^[7]。これはユーザー体験とエンゲージメントを向上させるため、推薦システム^[26]、チャットボット^[29]、ヘルスケア^[20]、教育^[31]をはじめとする広範な応用領域で重要な技術となっている。大規模言語モデル

(LLMs)^[5,8,12] はテキスト生成・推論・指示追従のいずれにおいても卓越した能力を示しており、さまざまな実世界のユーザー向けアプリケーションで活用されている。そのため、個々のユーザーの選好に合わせて LLM をパーソナライズすることは、重要な研究テーマとなっている^[25]。

人間フィードバックからの強化学習 (Reinforcement Learning from Human Feedback, RLHF)

は、学習済み LLM を人間の選好に整合させるための広く採用されている枠組みであり^[53]、複数の生成結果に対する選好比較またはランキングの形で人手フィードバックを用いて LLM をファインチューニングする。しかしながら、標準的な RLHF の手法では暗黙のうちに「すべての人間の選好が同一の分布に従う」と仮定しており^[53,45,33,36]、フィードバックに含まれるユーザー選好が多様または相反している状況では、かかる仮定の下でファインチューニングされた LLM が個別化された応答を生成する能力を制限してしまう^[22]。RLHF を基盤としたパーソナライズド LLM 出力の開発に関する近年の取り組み^[49,19] では、各選好次元（完全性、丁寧さなど）ごとに別個の報酬モデルや LLM を訓練する必要があるため、大規模で多様なユーザー基盤を抱える設定では計算およびストレージの面で課題が残る。そのうえ、これらの手法は事前に定義された選好次元に依存しているため、実世界の場面でユーザー選好次元を網羅的に列挙することが困難な場合、柔軟性が制約される。

効率的で柔軟なパーソナライズド LLM を構築するため、本研究ではユーザー情報のテキスト形式と、選好形式の履歴フィードバックデータの双方を利用する「個別化された人間フィードバックからの学習 (Learning from Personalized Human Feedback, 第4章)」の設定を導入する。まず標準 RLHF (第3章) がパーソナライゼーションにおいて抱える欠点を形式的に明らかにし、その後、図1に示すようなパーソナライズド RLHF (P-RLHF) の汎用フレームワークを提案する。提案フレームワークは、軽量のユーザーモデルを用いて、ユーザー情報から得られる明示的な選好とフィードバックデータから得られる暗黙的な選好を捉える。これは選好次元を事前に定義したりテキストで完全に記述したりすることが難しい場合に特に有用であり、欠落した情報をフィードバックデータから柔軟に推定することで、より包括的なユーザー選好理解を可能にする。

提案フレームワークを実例化するため、ユーザー選好に関する異なる仮定がユーザーモデルの設計にどう影響するかを議論する (第4.3節)。P-RLHF は、Personalized Direct Preference Optimization (P-DPO, 第4.4節) として開発された新しい学習目的を通じてユーザーモデルと LLM を同時に学習する。ユーザーモデルを組み込むことで P-RLHF は複数の報酬モデルや LLM を別個に訓練する必要を排除し、大人数ユーザーに対して効率的かつスケーラブルなパーソナライゼーションを実現する。公開されている選好データセットを用いた三つのタスク—相反する選好をもつ合成生成タスク、GPT-4 により多様なユーザープロファイルでラベル付けされた半合成の指示追従タスク、1,500 名のユーザーによる実世界の対話タスク—を通じて、P-DPO が LLM の挙動を個々のユーザー選好に効果的に整合させ、ユーザー基盤が大規模になっても効率的にスケールすることを実証する (第5章)。

図1: Personalized RLHF フレームワークの構成概要




図1: Personalized RLHF フレームワーク。パーソナライズド LLM（オレンジ強調）は学習対象ユーザーモデルと Base LLM の二構成要素からなる。学習時、3 名のユーザー ($i = 1, 2, 3$) から収集したユーザー情報 u_i と選好データを用いて、ユーザーモデルがユーザー固有埋め込み e_i と全ユーザー共通の埋め込み e_0 を出力し、これらが新しい P-RLHF 学習目的（第4.4節）により Base LLM と同時に学習される。生成時、学習時に観測されたユーザーには学習済み埋め込み e_i が、学習時には観測されなかった新規ユーザーには共通埋め込み e_0 が用いられる。

2. 関連研究 (Related Work)

人間フィードバックからの強化学習 (RLHF)

RLHF は人間の選好に整合する応答を生成するよう LLM を RL 方策として最適化する [45,33,3]。RLHF 訓練には、選好データから報酬モデル (Reward Model, RM) を学習し、近接方策最適化 (PPO) [42] を用いて学習済み報酬モデルに対し LLM を最適化する手順と、Direct Preference Optimization (DPO) [36] のように選好データから直接 LLM を最適化する手順があり、後者は訓練効率の面で大幅な改善をもたらす。標準的な RLHF 手法は暗黙のうちにユーザー選好の一様性を仮定しており、ユーザー間の多様性を見逃すため、特に実用上取得困難であることが多く LLM に提供されない明示的なユーザー選好仕様が与えられない場合、ファインチューニング後の LLM が個別化されたコンテンツを生成する能力を制約する。

RLHF にパーソナライゼーションを導入するため、近年の研究では異なる選好次元ごとに別個の報酬モデルや LLM 方策を学習し、報酬重みをカスタマイズする [49]、あるいは特定の選好選択に基づいて LLM をマージする [19] ことによりパーソナライズド LLM 出力を実現する手法を提案している。本研究はこれらの従来研究と次の二点で異なる。第一に、本研究のパーソナライズド LLM は事前定義された選好次元に依存せず、ユーザー情報とパーソナライズされたフィードバックデータから直接学習される。第二に、複数の LLM や報酬モデルを必要とせず、ユーザーモデルを用いて Base LLM のみを拡張する。同時に、ユーザー選好の多様性に対処する別の方向性として、グループ不変学習 [51] や分布ロバスト最適化 [6] などの手法を用い、異なるユーザーグループに対してロバストに振る舞う LLM 方策を学習する研究も存在する。ユーザーごとにパーソナライズされたコンテンツを生成する本アプローチとは異なり、これらの手法は公平性の観点からユーザーグループ間の性能差を最小化するコンテンツ生成を可能にするものであり、LLM のパーソナライズを行うものではない。

プロンプトベース LLM パーソナライゼーション

RLHF に基づくアプローチに加えて、プロンプトベース LLM パーソナライゼーションは、個々のユーザーの選好を捕捉し、それに応じて出力を調整する prompting 技術の開発に焦点を当てる。これは通常、ユーザーの履歴生成コンテンツを few-shot 例としてプロンプトに含めることで、文脈内学習を通じて LLM がパーソナライズド コンテンツを生成できるようにするものである [9,21]。近年の研究では、関連ユーザー データを構築するための検索手法を組み合わせる [40,41,50,27]、あるいはユーザー情報の要約でプロンプトを拡張する [38] ことによって、この手法をさらに改善している。本研究はプロンプトベース LLM パーソナライゼーションと相補的な関係にある。プロンプトベース手法がユーザー生成コンテンツ (ユーザー執筆テキストや選択アイテムなど) を活用するのに対し、本研究は比較やランキングという形式の選好データ—エンドユーザーから得られる標準的なフィードバック形態で、ユーザー生成コンテンツを補完し、暗黙的なユーザー選好を捉える—を用いて LLM のパーソナライゼーションを行う。したがって LaMP[40] のようなプロンプトベース ベンチマークは、本手法に直接適用できない。

紙幅の都合上、クラウドソーシングや条件付き自然言語生成を含む関連研究の追加部分は付録 A で議論する。

3. 標準 RLHF (Vanilla RLHF)

標準 RLHF パイプラインの概要を DPO を含めて手短かに振り返り、パーソナライゼーションにおけるその欠点を考察する。標準 RLHF には三つのステップがある [53,33]：(1) 教師あり微調整 (Supervised Fine-Tuning, SFT) データセットを用いて教師あり微調整済み方策 π_{SFT} を取得する；(2) 選好データセットを用いて報酬モデル (Reward Model, RM) を学習する；(3) 学習済み報酬モデルに対し、PPO^[42] 等の手法を用いて LLM を最適化する。学習済み報酬モデルと RL 目的の下での最適 LM の再パラメータ化に基づき、DPO^[36] は選好データセットを用いて LLM を直接最適化する。

3.0.1 報酬モデリングによる標準 RLHF

標準的な報酬学習者は選好データセット $\mathcal{D} = \{(x_i, y_{i,1}, y_{i,2})\}_{i=1}^n$ にアクセスする。各サンプルにおいて、 x_i はプロンプト、 $y_{i,1}$ と $y_{i,2}$ は二つの生成テキストであり、プロンプト x_i のもとで $y_{i,1} \succ y_{i,2}$ (すなわち $y_{i,1}$ が $y_{i,2}$ より選好される) とする。プロンプト x と生成テキスト y の組からスカラー値を返す報酬モデルは次式により学習される：

$$r_{\text{vanilla}} \in \arg \min_r - \mathbb{E}[\log \sigma(r(x, y_1) - r(x, y_2))]. \quad (1)$$

ここで σ はシグモイド関数、最小化はすべての可測関数の上で行う。Zhu ら [52]、Rafailov ら [36] が指摘するように、式 (1) を用いて報酬モデル r_{vanilla} を学習するための根底にある仮定は、ユーザー選好が Bradley-Terry (BT) モデル^[4] に従うというものである。すなわち、すべてのプロンプト x と生成テキスト y_1, y_2 に対して、ユーザー選好が次式に従うという仮定である：

$$P(y_1 \succ y_2 | x) = \frac{\exp(r(x, y_1))}{\exp(r(x, y_1)) + \exp(r(x, y_2))} = \sigma(r(x, y_1) - r(x, y_2)). \quad (2)$$

r_{vanilla} を学習した後、LLM 方策 π_{vanilla} は KL ダイバージェンスペナルティの下で報酬を最大化することで学習される。このペナルティは学習 LLM と SFT 方策 π_{SFT} の逸脱を制御する：

$$\pi_{\text{vanilla}} \in \arg \max_{\pi} \mathbb{E}[r_{\text{vanilla}}(x, y)] - \beta \mathbb{E}_{x \sim p}[\text{KL}(\pi(\cdot | x) \parallel \pi_{\text{SFT}}(\cdot | x))]. \quad (3)$$

ここで KL は KL ダイバージェンス、 $\beta > 0$ はペナルティの強さを制御する調整可能なパラメータである。

3.0.2 標準 DPO

DPO は RM に基づく RLHF 手法の代替である。Rafailov ら [36] が指摘するように、任意の RM r が与えられたとき、式(3)のもとで対応する最適方策は次のように書ける：

$$\pi(y | x) = \frac{1}{Z(x)} \exp(r(y | x)) \exp\left(\frac{r(x, y)}{\beta}\right). \quad (4)$$

ここで $Z(x)$ は生成テキストに依存しない (y に依存しない) 正規化因子である。式 (4) を報酬目的 (1) に代入すると、 π_{vanilla} を求める次の式が得られる：

$$\pi_{\text{vanilla}} \in \arg \min_{\pi} - \mathbb{E}_{(x, y) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_{\text{vanilla}}(y|x)}{\pi_{\text{SFT}}(y|x)} - \beta \log \frac{\pi_{\text{vanilla}}(y|x)}{\pi_{\text{SFT}}(y|x)} \right) \right]. \quad (5)$$

この再パラメータ化のもとで、対応する標準 RM r_{vanilla} は $r_{\text{vanilla}}(x, y) = \beta \log \frac{\pi_{\text{vanilla}}(y|x)}{\pi_{\text{SFT}}(y|x)} + \beta \log Z(x)$ と書ける。以下では、標準 RLHF におけるユーザー選好に関する根底にある仮定を振り返り、パーソナライズドなコンテンツ生成のための、当該仮定の下でファインチューニングされた LLM の限界を明らかにする。

本節では、報酬モデリング ステップ (式(1)) を通じて明示的に学習された、あるいは DPO (式(5)) を通じて暗黙的に学習された r_{vanilla} の挙動と根底にある仮定を調べる。対応する仮定が、ユーザーが多様または相反する選好をもつ場合に特に問題があることを示す。本節の証明は付録 B に記載する。

Ziegler ら^[53]と同様、報酬学習者はプロンプトと生成テキスト (x, y_1, y_2) に加えて、選好（およびアノテーション）を提供するユーザーの識別情報 $u \in \mathcal{U}$ にアクセス可能であることが多い。標準 RLHF では、ユーザー選好が BT モデル (式(2)) に従うと明示的に仮定する一方、選好の一様性という暗黙の仮定をしばしば見過ごしている：

仮定 3.1 (選好の一様性, Preference Uniformity)。 標準的な報酬モデリングおよび DPO においては、すべての $u \in \mathcal{U}$ に対し、ユーザー選好が一様、すなわち次式が成立すると仮定される：

$$P(y_1 \succ y_2 \mid x, u) = P(y_1 \succ y_2 \mid x).$$

この仮定は、事実性や安全性といった異なるユーザーに共通する選好を明らかにすることが目標である場合には合理的であり得る。ユーザー選好が多様である設定（生成テキストのスタイルなど）においては、この仮定は望ましくない可能性がある。これを、まず r_{vanilla} が訓練データセット上でどう振る舞うかを分析することで示し、その後、選好の一様性仮定 3.1 に関する一般的な問題を議論する。

レマ 3.2 [r_{vanilla} は多数決と等価]。 すべての $i \in [n]$ に対し、 r_{vanilla} の下で推定されるユーザー選好は次式で与えられる：

$$P(y_{i,1} \succ y_{i,2} \mid x_i) = \sigma(r_{\text{vanilla}}(x_i, y_{i,1}) - r_{\text{vanilla}}(x_i, y_{i,2})) = \frac{\sum_{j \in [C_i]} 1\{y_{j,1} = y_{i,1}\}}{|C_i|},$$

ここで $C_i = \{j \in [n] : x_j = x_i, y_{j,1} = y_{i,1}, y_{j,2} = y_{i,2}\} \cup \{j \in [n] : x_j = x_i, y_{j,1} = y_{i,2}, y_{j,2} = y_{i,1}\}$ はサンプル i と同一のプロンプト・応答対を共有するサンプル指標の集合である。

上記のレマは直接的ではあるが、 r_{vanilla} が抱える根本的な問題の一つを示している。すなわち、 r_{vanilla} は多数決体制を誘導し、多数派に選好された応答がすべてのユーザーにも選好されると仮定する。選好の多様性が重要となるパーソナライゼーション設定では、このような多数決方式はマイノリティ コミュニティの選好を黙殺する可能性がある。最悪の場合、多数派と少数派の選好が対立するとき、LLM の生成物は少数派ユーザーの選好と完全に整合しない可能性がある。

選好の一様性仮定 (3.1) についてさらに考察すると、この仮定のもとでは、少数派と多数派のグループで選好が異なる場合、その真の選好 $P(y_1 \succ y_2 \mid x, u_{\text{minority}})$ は、 $P(y_1 \succ y_2 \mid x, u_{\text{majority}})$ と比較して、仮定された一様選好 $P(y_1 \succ y_2 \mid x)$ からの逸脱度が必ず大きくなる。さらに、この逸脱度は多数派グループのサイズが増大するにつれて増大する。

レマ 3.3。 $P(u_{\text{majority}}) \geq P(u_{\text{minority}})$ であるとき、次式が成立する：

$$|P(y_1 \succ y_2 \mid x) - P(y_1 \succ y_2 \mid x, u_{\text{minority}})| > |P(y_1 \succ y_2 \mid x) - P(y_1 \succ y_2 \mid x, u_{\text{majority}})|.$$

さらに、多数派グループのサイズが増大するにつれて、少数派グループの仮定一様選好からの逸脱度

は大きくなる、すなわち $|P(y_1 \succ y_2 | x) - P(y_1 \succ y_2 | x, u_{\text{minority}})|$ は $P(u_{\text{majority}})$ に関して単調増加である。

レマ 3.2 と 3.3 は、標準的な報酬モデリング (式(1)) または標準 DPO (式(5)) のもとで得られる r_{vanilla} が、ユーザー選好が多様である場合に適さない可能性があることを示している。以下では、ユーザー個々の選好を捉えることで当該枠組みの下で学習された LLM がユーザーごとに個別化されたコンテンツを生成できるようにする、Personalized RLHF の手法を提案する (第4.2節)。まず個別化フィードバックからの学習タスクを形式的に定義する。

4. 個別化された人間フィードバックからの学習

4.1 パーソナライズド LLM：問題設定

個別化された選好データセットが与えられたときの学習設定を形式的に定義する。個別化された人間フィードバック（選好）データセット $\mathcal{D}_p = \{(x_i, y_{i,1}, y_{i,2}, u_i)\}_{i=1}^n$ は、 n 個のサンプルで構成され、 $u_i \in \mathcal{U}$ はデータをアノテーションした、あるいは選好を提供したユーザーの情報、 x_i はプロンプト、 $y_{i,1}$ と $y_{i,2}$ はユーザー選好のもとで $y_{i,1} \succ y_{i,2}$ となる二つの生成テキストである。本研究では、ユーザー情報が $u_i = (u_i^t, u_i^p)$ の形式をとるケースを考える。 u_i^t は任意指定可能なテキスト情報（人口統計データやユーザーの選好記述など）、 u_i^p はユーザー固有の i 識別子（割り当てられたアノテーション ID やユーザー ID など）である。新規の未知ユーザーに対しては、識別子を $u^p = u_0$ に設定し、そのユーザー テキスト情報 u^t は任意とする。

パーソナライズド LLM π_p はプロンプト x とユーザー情報 $u \in \mathcal{U}$ を受け取り、ユーザー u の個人的選好（ u^t で明示的に指定される、あるいはそのフィードバックデータに暗黙的に符号化されたもの）に基づいてテキスト生成をカスタマイズする。すなわち $y \sim \pi_p(\cdot | x, u)$ である。テキスト情報が存在しない、すなわち $u^t = ()$ で、かつユーザー インデックスが未知、すなわち $u^p = u_0$ である場合、LLM π_p は非個別化された応答を生成する。以下ではパーソナライズド LLM π_p を構築するための一般枠組みを提示する。

4.2 P-RLHF 一般フレームワーク

パーソナライズド LLM 開発のため、まず Personalized-RLHF (P-RLHF) の一般枠組みを提示する。パーソナライズド LLM を構築する際、しばしば π_{SFT} である Base LLM から始め、次の二要素を規定する：

- ユーザー情報 $u = (u^t, u^p)$ からユーザー埋め込み（テンソル） e_u を抽出する学習対象ユーザーモデル f_P 。すなわち、すべての $u \in \mathcal{U}$ に対し、ユーザー埋め込みは $e_u = f_P(u)$ で与えられる。

したがって、パーソナライズド LLM π_p はユーザーモデル f_P と Base LLM で構成される（図1参照）。以下にユーザーモデルの例をいくつか提示する。その後、新しい目的関数（P-DPO 等）を用いてユーザーモデルとパーソナライズド LLM を学習する方法を述べる。

4.3 P-RLHF ユーザーモデル

ユーザーは自身の背景情報や選好をテキスト情報 u^t に記述し得るが、テキスト化されないがフィードバックに反映される選好次元がしばしば存在する。ユーザー選好の包括的理解を保証するため、P-RLHF は u^t で記述される明示的な選好とフィードバックデータに符号化された暗黙的な選好の両方を捕捉し、それらを統合して個別化されたコンテンツ生成を行う。したがって、ユーザーモデル f_P は二つの構成要素、すなわち二つの側面に対応する明示的ユーザーモデル f_P^{ex} と暗黙的ユーザーモデル f_P^{im} を含むよう設計される。

明示的ユーザーモデル f_P^{ex} はテキスト情報 u^t を受け取り、ユーザー u のための明示的ユーザー埋め込み e_u^{ex} を出力する。LLM の自然言語理解能力を活用し、 u^t に対する LLM が提供するテキスト入

力埋め込みを明示的ユーザー埋め込みとして直接用いる。具体的には $e_u^{\text{ex}} \in \mathbb{R}^{T_{\text{text}} \times d}$ で、 T_{text} は u^t におけるトークン数、 d は LLM のトークンごとの埋め込み次元である。この手法は u^t が LLM の表現空間と整合した形で符号化されることを保証し、ユーザー テキスト情報 u^t が空となるシナリオを柔軟に処理する。

暗黙的ユーザーモデル f_P^{im} は、 u^t で明示化されていないがフィードバックデータに潜在する追加的なユーザー選好を捕捉する。これらの暗黙的な選好のより効率的な学習を促進するため、 f_P^{im} を、異なるユーザーの選好が互いに関係するかを表す特定の選好仮定を符号化するよう構成する。以下では f_P^{im} の定義方法を示す。暗黙的ユーザー選好はテキスト ユーザー情報に頼らず学習される。これは固有ユーザー識別子 u^p を直接その埋め込み $e_u^{\text{im}} \in \mathbb{R}^{T_u \times d}$ に写像する。 T_u は暗黙的ユーザー埋め込みのユーザー トークン長であり、暗黙的埋め込みの表現力を制御する因子である。簡単のため、本研究では識別子をインデックスとして扱う：既知ユーザーの場合 $u^p = i \in \{1, \dots, m\}$ (m はユーザー総数)。推論時に新たに現れる未知ユーザーはインデックス $u^p = 0 = u_0$ を割り当てる。以下に暗黙的ユーザーモデル f_P^{im} の例をいくつか示す。

例 1 (一様選好, Uniform Preference)。 $I = \{0\} \cup [m]$ を $\mathcal{U}$ におけるユーザーの指標集合とする。すべての $i \in I$ に対し、暗黙的ユーザーモデル $f_P^{\text{im}}(i) = e_0^{\text{im}}$ は同じ埋め込みを出力する。この埋め込み e_0^{im} は空テンソルでもよいことに留意されたい。このユーザーモデルは全ユーザーが同一埋め込みを共有すると仮定するもので、標準 RLHF の基本的な仮定に対応する。

例 2 (個別化選好, Individualized Preference)。 暗黙的ユーザーモデルは、 $f_P^{\text{im}}(0) = e_0^{\text{im}}$ を (未知ユーザー用にインデックス 0 で) 出力する。すべての $i \in [m]$ に対し、ユーザーモデルは次式を出力する：

$$f_P^{\text{im}}(i) = e_u^{\text{im}} = e_0^{\text{im}} + o_i,$$

ここで o_i はユーザー固有のオフセットテンソルである。

このユーザーモデルは、インデックス i のユーザーが e_0^{im} という事実性・安全性などのユーザー共通の構成要素を保ちつつ、 o_i という個別化された選好オフセットをもつと仮定する。共通のユーザー埋め込み e_0^{im} と個別オフセット o_i がベクトルである場合、このユーザーモデルは埋め込みテーブルとして実装可能である。

例 3 (クラスターベース選好, Cluster-based Preference)。 すべての $i \in I$ に対し、ユーザーモデルは次式を出力する：

$$f_P^{\text{im}}(i) = e_i^{\text{im}} = V \cdot w_i,$$

ここで V は K 個のクラスター中心を含む埋め込みテーブル (K はクラスター数)、 $w_i \in \mathbb{R}^K$ は各ユーザーの重みベクトルである。

クラウドソーシング文献^[18]に着想を得て、各ユーザーの埋め込み (ひいては選好) は V が与える共通ベクトル集合のスパンにわたると仮定するクラスタリングベースの暗黙的ユーザーモデルを発展させた。各ユーザーの埋め込みはこれらのベクトルの重み付き線形結合である。 w_i が one-hot ベクトルである特殊ケースでは、各暗黙的ユーザー埋め込みは V の行となり、ユーザー埋め込みはクラスターを形成する。効率性の観点からは、クラスターベース選好モデルは低ランク近似と見なすこともできる。すなわち、各 $(m+1)$ ユーザーの異なる埋め込み (サイズ d) をもつ代わりに (サイズ

$(m+1) \times T_u \times d$ の埋め込みテーブル V^{ind} が得られる)、ここでは $V^{\text{ind}} \approx W^{\text{cluster}} V$ と近似する。 $V \in \mathbb{R}^{K \times T_u \times d}$ はクラスタ中心の埋め込みテーブル、 $W^{\text{cluster}} \in \mathbb{R}^{(m+1) \times K}$ はその第 i 行が w_i である埋め込みテーブルである。

最後に、ユーザーモデル $f_P(u) = \text{concat}(f_P^{\text{im}}(u^p), f_P^{\text{ex}}(u^t))$ が結合された暗黙的・明示的ユーザー埋め込みを LLM に渡し、パーソナライズド応答生成を行う（図2参照）。図1の青枠で示すように、既知ユーザー $u \in \mathcal{U}$ に対する応答生成では、LLM は明示的選好を符号化する e_u^{ex} と暗黙的選好を符号化する e_u^{im} の両方を活用し、ユーザー固有の選好に合わせて出力を調整できる。テキスト情報を持たない未知ユーザー、すなわち $u^t = ()$ かつ $u^p = u_0 = 0$ の場合、LLM は標準 RLHF と同様に、学習時に観測されたユーザー全員に共通する選好を捕捉する共通暗黙的埋め込み e_0^{im} のみを用いて非個別化された応答を生成する。このケース（ユーザー固有情報なし）では、標準 RLHF からの非個別化 LLM はモデルが実現できる最良出力とみなせる。テキスト情報 u^t を持つが観測されなかった新規ユーザーに対しては、LLM は e_u^{ex} と e_0^{im} を活用し、フィードバックデータが不在の状況でも、ユーザー固有の明示的選好と共通の暗黙的選好を組み合わせ、観測外ユーザーに対する LLM を効果的にウォームアップできる。

4.4 P-RLHF 学習目的：Personalized DPO

学習対象ユーザーモデル f_P が与えられたとき、各ユーザー $u \in \mathcal{U}$ に対し $e_u = \text{concat}(e_u^{\text{im}}, e_u^{\text{ex}}) \in \mathbb{R}^{(T_u + T_{\text{text}}) \times d}$ のユーザー埋め込みを得る。これをソフトプロンプティング [24] によりパーソナライズド LLM に統合する。この場合、 e_u は Base LLM によって与えられる入力（テキスト位置ではない）埋め込みの先頭に連結され、 d は上述のトークンごとの埋め込み次元である。対応するユーザーモデル f_P とともにパーソナライズド LLM π_P を指定した上で、P-DPO においては次の学習目的を用いる：

$$\min_{\theta_P} - \mathbb{E} \left[\alpha \log \sigma \left(\beta \log \frac{\pi_P(y^+ | x, u^t, u^p)}{\pi_{\text{SFT}}(y^+ | x, u^t, u^p)} \right) - \beta \log \frac{\pi_P(y^+ | x, u^t, u^p)}{\pi_{\text{SFT}}(y^+ | x, u^t, u^p)} + (1 - \alpha) \log \sigma \left(\beta \log \frac{\pi_P(y^- | x, u^t, u^p)}{\pi_{\text{SFT}}(y^- | x, u^t, u^p)} \right) - \beta \log \frac{\pi_P(y^- | x, u^t, u^p)}{\pi_{\text{SFT}}(y^- | x, u^t, u^p)} \right]. \quad (\text{P-DPO})$$

ここで $\beta > 0$ は π_P の π_{SFT} からの逸脱を制御する。本損失は、ユーザー識別子 u^p に依存するユーザー識別子固有損失項と u_0^p に依存するユーザー識別子非依存損失項の組み合わせとみなせる。ユーザー識別子非依存損失は、ユーザー識別子をすべて 0 に設定した同じ選好データを用いる。ハイパーパラメータ $\alpha \in [0, 1]$ は二つの損失成分の寄与を制御する。

注 4.1. P-RLHF 学習目的の一般構造は、DPO 損失のパーソナライズに限定されず機能する。実際、もとの選好最適化目的における $\pi(y | x)$ をそれぞれ $\pi_P(y | x, u^t, u^p)$ および $\pi_P(y | x, u^t, u_0^p)$ に置換することで、任意の選好最適化目的をユーザー固有およびユーザー非依存損失に変更できる。付録 F.3 で詳細を議論する。

5. 実験 (Experiments)

個別ユーザー選好に整合したパーソナライズド LLM を構築するうえでの P-DPO の効果を実証的に評価する。本研究では三つのオープンエンド テキスト生成タスクを用いる一理想とするパーソナライズド LLM 挙動を導出できる完全に統制された合成設定 (第5.1節) から始まり、GPT-4 で異なる選好プロファイルによりラベル付けされた半合成設定 (第5.2節)、そして多様な人口統計的背景と選好をもつ大人数ユーザーによる実世界設定 (第5.3節) に進む。

5.1 相反する選好を持つ生成

統制された合成設定

TL;DR データセットを用いる。各比較には Reddit 投稿 x 、二つの要約 y_1, y_2 、およびそれをアノテーションしたワーカー id が含まれる^[45]。本手法の有効性を検証するため、二つの模擬選好をもつ完全に統制された設定を設計した：ワーカーの 70% をランダムに抽出して長い応答を選好するように、残りの 30% を短い応答を選好するように設定し、長い応答への選好をデータ内の多数派グループ、短い応答への選好を少数派グループとして、両者の選好が相反するようにした。選好を十分なデータで有効に学習させるため、TL;DR データセットの訓練分割で最もアノテーション数の多い上位 10 名のワーカーを訓練に含めた。これらは参照用として id 1 ~ 10 で示す。模擬後、ワーカー 4, 5, 6 は短い応答を選好し (少数派グループ)、残る 7 名は長い応答を選好する (多数派グループ) ことになる。データセットのさらなる詳細は付録 C.1 に示す。個別化選好仮定 (例2) を符号化するユーザーモデル、 $\alpha = 0.5$ 、 $T_u = 10$ で実験した。SFT モデルとして fine-tuned GPT-J 6B モデル^[47]を用いる。

最適パーソナライズド LLM の期待挙動

客観的な尺度 (応答長など) に基づいてユーザー選好を模擬することで、最適パーソナライズド LLM の次の二種類の理想挙動を解析的に導出できる：

- **E1.** 常に短い応答を選好するユーザー (少数派ユーザー) に対しては、真の報酬が Bradley-Terry モデルに従う： $P(\text{short response} \succ \text{long response} \mid x, u) = 1 = \sigma(r(x, \text{short response}, u) - r(x, \text{long response}, u))$ 。したがって $r(x, \text{short}, u) - r(x, \text{long}, u) = +\infty$ が成り立ち、長さ 0 の応答が最大報酬を得る。よって、当該ユーザーに対するパーソナライズド LLM の最適挙動は長さ 0 の応答を出力することである。
- **E2.** 観測されなかった未知ユーザーに対する応答生成時には、ユーザー非依存損失で訓練された共通暗黙的ユーザー埋め込みを用いるパーソナライズド LLM は、理想的には標準 DPO でファインチューニングされた LLM と同様に振る舞うべきである。これは、追加のテキスト ユーザー情報がない場合、パーソナライズド LLM は非パーソナライズド モデルと同様に振る舞うべきだからである。

応答長のような客観的な尺度に基づいてユーザー選好を模擬することで、こうした最適パーソナライズド LLM の期待挙動を解析的に導出し、学習した LLM が当該挙動を示すかを評価することで P-DPO の有効性を確認できる。

評価集合からランダムに抽出した 50 件のプロンプトに基づき、各ワーカーに対して P-DPO でファインチューニングされたパーソナライズド LLM が生成した応答の長さ（単語数で計測）を下図に示す：



図3: 個別化選好を持つ P-DPO がワーカー 1~10 に対して生成した応答の単語数（平均と標準誤差）。SFT (S)、vanilla DPO (V)、共通ユーザー埋め込みを用いた P-DPO (G) と比較。P-DPO は短い応答を選好する少数派ワーカー 4, 5, 6 に対してのみ長さ 0 の応答を生成した。

結果は、パーソナライズド LLM が多数派ワーカーに対しては有意に長い応答を、少数派ワーカー 4, 5, 6 に対しては end-of-text トークン（すなわち長さ 0 の応答）のみを生成したことを明確に示しており、模擬選好から導出した E1 の期待最適挙動を示した。訓練データには空の応答が含まれなかったにもかかわらず、少数派ユーザーに対して長さ 0 の応答を生成できた LLM の能力は、訓練データを越えて正しく外挿したことを示している。さらに、新規ユーザー（オレンジバー）で暗黙的共通埋め込みを用いて P-DPO モデルが生成する応答長は vanilla DPO（青バー）に類似している。選好の一様性仮定のもと、vanilla DPO は相反する選好を含むデータで支配的選好（長い応答）に整合するため、SFT（紫バー）よりも長い応答を生成する。暗黙的共通ユーザー埋め込みを用いた P-DPO も同様に vanilla DPO に類似した挙動を示し、E2 の理想挙動を示している。注目すべきは、選好を示す明示的なテキスト ユーザー情報が提供されなかったにもかかわらず、パーソナライズド LLM がフィードバックデータに符号化された暗黙的な長さ選好を首尾よく捕捉したことである。

追加結果として、応答長に加えて、P-DPO 学習目的により定義される暗黙的報酬の正確性、および P-DPO ハイパーパラメータの影響、ユーザーモデルの設計選択（異なるユーザークラスタモデル）、より大規模なユーザー数（10 ではなく 40）へのスケーリングに関するアブレーション研究も実施した。詳細は付録 C.3 および C.4 を参照されたい。

5.2 異なる選好プロファイル下での指示追従

設定：複数選好次元に基づく多様なユーザープロファイル

フィードバックデータから単一次元のユーザー選好を捕捉する（第5.1節） P-DPO の能力を踏まえ、複数の選好次元にわたるより多様なユーザープロファイルをもつより厳しい設定で本手法を検証する。これにより、ユーザーが選好を完全に明示化できない実世界シナリオで特に有用となる、フィードバックデータから暗黙的選好を直接推定する本手法の能力をさらに評価する。Personalized-

Soups (P-SOUPS) データセット^[19]は GPT-4 Alpaca^[34]への指示に対するペアワイズ フィードバックを含む。応答は Tulu-7B^[48]からサンプリングされ、比較は専門性・情報量・スタイルという三つの事前定義次元に関する選好プロンプト (P1, P2, P3 と表記) を用いて GPT-4 によりアノテーションされた。各次元について二つの対称選好 (A および B と表記) が存在し、合計六つの異なる選好プロファイルが得られる。本実験では、各選好プロファイルを個別ユーザーとして扱い、ユーザー 1, 2, 3, 4, 5, 6 がそれぞれ選好プロファイル P1A, P1B, P2A, P2B, P3A, P3B に対応する。P-SOUPS データセットおよび前処理手順の詳細は付録 D に記載する。P-SOUPS については、ユーザー選好の明示的なテキスト仕様をモデルに提供せず、個別化選好、 $\alpha = 0.5$ 、 $T_u = 10$ を持つ P-DPO での実験に焦点を絞った。

表1: GPT-4 により評価された、P-DPO の三つの手法に対する勝率 (%)。「Pref」は「Preference Prompt」を省略したもの。各ユーザーの勝率は正解の選好プロンプトを用いて評価される一方、P-DPO は訓練・テスト時にこうした選好プロンプトにアクセスしない。各手法について、全 6 ユーザーにおける平均と標準誤差 (SE) を最終列に示す。

ベースライン手法	User 1	User 2	User 3	User 4	User 5	User 6	平均 ± SE
Tulu SFT (選好プロンプトなし)	91.67	86.36	100.00	59.57	96.00	100.00	88.93 ± 5.70
Tulu vanilla DPO	95.92	86.67	100.00	63.04	100.00	100.00	90.94 ± 5.45
Tulu SFT (選好プロンプトあり) = オラクル	73.47	74.42	90.48	48.00	59.09	76.00	70.24 ± 5.50

ベースライン種別：① Tulu-7B SFT (選好プロンプトなしで指示を入力)、② 選好プロンプトなしのペアワイズ フィードバックを用いて vanilla DPO でファインチューニングした Tulu-7B、③ 選好プロンプトありの指示でプロンプトされた Tulu-7B (オラクル)。

パーソナライズド LLM の理想性能

P-DPO の性能は、二つのベースライン モデルおよび一つのオラクル モデルと比較する。上述のように、二つの非パーソナライズド ベースライン：① 選好プロンプトなしで指示を入力された Tulu-7B SFT、② 入力に選好プロンプトを含まないペアワイズ フィードバックを用いて vanilla DPO でファインチューニングされた Tulu-7B である。P-DPO の訓練および評価には指示のみが LLM に提供され、選好プロンプトは提供されないため、P-DPO はフィードバックデータからのみユーザー選好を学習できる。パーソナライズド LLM は P-DPO でファインチューニングした後、ベースラインよりも個々のユーザー選好により整合した応答を生成すると期待される。パーソナライズド生成の品質をさらに評価するため、P-DPO を「オラクル」のパーソナライズド手法 ③ (指示と正解選好プロンプトでプロンプトされた Tulu-7B) と比較する。③ は各ユーザーの実際の選好を LLM に直接指定す

らず、達成すべき最良性能を表す。文献^[19]に倣い、Kala 評価^[14]の50件の指示に対する P-DPO モデルと上述三つのモデルの生成物間のペアワイズ勝率を、GPT-4 によりアノテーションされた AlpacaFarm ベースの枠組み^[13]を用いて評価する。

P-DPO から学習された LLM の観測性能

各個別ユーザーに対する勝率を表1に示す。ベースライン ① および ② では、すべてのユーザーに同一の生成物が使用された。明示的なユーザー選好にアクセスしないにもかかわらず、P-DPO は Tulu-7B SFT および vanilla DPO によりファインチューニングされた Tulu-7B (ベースライン ① および ②) を、平均約 90% の勝率で上回った。一部のユーザープロファイル (例: ユーザー 3 および 6 は簡潔/非友好的な応答を選好) では勝率は 100% に達した。興味深いことに、選好プロンプトなしの DPO ファインチューニング Tulu-7B に対する P-DPO の勝率は、事前学習済み Tulu-7B SFT と同等かそれ以上であり、データに多様で相反する選好が存在する場合に標準 RLHF 手法が直面する困難を反映する。正解ユーザー選好にアクセスするオラクル パーソナライズド手法 ③ と比較すると、P-DPO は 6 ユーザー中 5 ユーザーで 59% 以上の勝率を達成し、平均 70.24% の勝率を達成した。以上の結果は、P-DPO がフィードバックデータに符号化された暗黙的なユーザー選好を強力に捕捉し、学習した選好に基づいて個別ユーザーに整合する能力を示す。

5.3 大規模ユーザーベースの実世界選好データセットにおけるパーソナライゼーション

設定: 大規模・実世界の選好データおよび複雑なユーザープロファイル・対話トピック

PRISM^[23] データセットは LLM との対話における人間の選好の多様性と信頼性を捉えることを目的とする。参加者の社会人口統計情報および表明選好を含む 75 か国 1,500 名の参加者、ならびに参加者の文脈選好と詳細なフィードバックを伴う 8,011 件の厳選ラベル付き対話を収録する。本研究者の知る限り、これはユーザー テキスト情報と識別子の両方を収録する、利用可能な最大規模の実世界パーソナライズド選好データセットである。このデータセットの規模と多様性は、パーソナライズド LLM の開発における特に困難なタスクおよびパーソナライゼーション手法の有効性評価のための強固なテストベッドとなる。PRISM データセットのさらなる詳細は付録 E.1 に示す。

各単一ターンを比較として扱うことで対話を処理した。各比較は、(1) 対話履歴とユーザー発話を含むプロンプト x 、(2) 社会人口統計データとユーザー表明選好を含むユーザー テキスト情報 u^t 、(3) 当該ターンにおける選好応答 y_1 と非選好応答 y_2 からなる。SFT モデルとして Llama3-8B-Instruct^[1]を用い、 $K = 10$ および $K = 100$ の個別化選好とクラスターベース選好を持つ P-DPO 手法を実験した。第5.2節と同様、GPT-4o によりアノテーションされたペアワイズ勝率をモデル性能評価に用いる。評価時、GPT-4o のロールプレイ プロンプトは各サンプル向けに調整される。これには (1) ユーザー情報 (社会人口統計、自己記述、書かれたシステム 文字列、表明された上位三つの選好側面); (2) フィードバックと文脈情報 (当該サンプルが抽出された対話後のユーザー フィードバック、および他のターンでのユーザー アノテーション) が含まれる。ロールプレイ プロンプトの例は付録 E.2 に示す。

パーソナライズド LLM の理想性能

まず、P-DPO から学習されたモデルと vanilla DPO から学習されたモデルを比較する。すべての手法はユーザー テキスト情報とともに訓練される。ユーザー 表明選好と社会人口統計が与えられた場合、vanilla DPO は強力なベースラインとなり得、この情報を活用してユーザー 選好を深く理解し生成をそれに応じて調整できる。しかしながら P-DPO は、フィードバックデータから暗黙的なユーザー 選好を推定し、ユーザー テキスト情報に存在する明示的な選好を補完することで、vanilla DPO を上回る潜在能力をもつ。この機能は、対話トピックの複雑さと、当該状況下でユーザー が自身の選好を完全に明示化することの難しさを考えると、特に重要となる。理想的には、パーソナライズド LLM は、暗黙的なユーザー 選好を考慮せずユーザー テキスト情報のみを用いて出力をパーソナライズする vanilla DPO に対して 50% 以上の勝率を達成するべきである。さらに、P-DPO モデルが生成した応答を PRISM データセットにおける選好応答とも比較する。選好応答もまた強力なベースラインであり、人間との対話のために高性能 LLM が生成した多様で高品質な生成物であり、人間の判断のもとで選好される出力とみなされるためである。パーソナライズド LLM が多様なユーザー 選好を効果的に捕捉した場合、選好応答と同等かそれ以上の性能を示し、勝率は概ね 50% ないしそれ以上となり得る。

P-DPO から学習された LLM の観測性能

表2に示す勝率から次のことが分かる：(1) すべての P-DPO モデルは vanilla DPO モデルを上回り、60% 以上の勝率を達成した。これらの結果は、本 P-DPO 手法が確かにユーザー テキスト情報に十分に記述されていない追加的な暗黙的な選好を捕捉し、学習した選好に基づいてより優れた個別化された応答を生成したことを示している。(2) すべての P-DPO モデルは選好応答を上回り、勝率は vanilla DPO モデル生成物に対するそれよりわずかに低い程度である。Vanilla DPO は選好応答に対して 50% 未満の勝率を達成し、ユーザー テキスト情報に記述された明示的な選好のみに依存することが不十分であることを示している。対照的に、明示的・暗黙的なユーザー 選好の両方を捕捉する P-DPO は、個々のユーザー 選好により整合した個別化された応答を生成し、選好応答を上回る。(3) PRISM においてはクラスターベース ユーザー モデルを持つ P-DPO が最良である。大規模ユーザー ベースにおいてクラスターベース ユーザー モデルは、ユーザー 選好の効率的な低ランク近似を提供し（例3で議論したように）、ユーザー 数の増加に対しても良好にスケールする。クラスターベース ユーザー モデルを用いて P-DPO によりファインチューニングされた最良性能のパーソナライズド LLM からの生成例は付録 E.3 に示している。「飲酒」という議論の余地があるトピックについて、ユーザー はモデルに人間の友人のように振る舞うことを求めている。P-DPO モデルのみが、良き聞き手のように適切に振る舞う応答を返している。

表2: 10 名の観測ユーザーおよび 10 名の未観測ユーザーからの 76 サンプルで評価された、vanilla DPO および選好応答に対する P-DPO 手法の勝率 (%)。「同点」は「両者勝利」として扱う。サンプル単位勝率とユーザー単位勝率の両方を示す。サンプル単位勝率は全個別サンプルにわたって集計され、ユーザー単位勝率は各ユーザーについて支配的に勝利したモデルを決定し (全サンプルで最も多く勝利したモデル)、ユーザー間で結果を集計することで算出される。

評価対象	Individualized P-DPO		Cluster-based P-DPO (K=10)		Cluster-based P-DPO (K=100)	
	サンプル単位	ユーザー単位	サンプル単位	ユーザー単位	サンプル単位	ユーザー単位
vs. Vanilla DPO	—	64.47	60.52	61.84	61.84	65.79
vs. Chosen response	42.11	—	—	—	—	—

※ 表中の数値は原論文の抜粋に基づく概略値。個別のセル値はソース Figure / Table 2 で確認可能。P-DPO 系はいずれも vs. Vanilla DPO で概ね 60–66% の勝率を達成し、vs. Chosen response でも選択応答の水準に並ぶ性能を示している。

暗黙的ユーザーモデルの有効性をさらに検証するため、PRISM データセット上でクラスターベース選好 $K = 10$ の、P-DPO の暗黙的ユーザーモデル専用バージョン (テキスト ユーザー情報なし) を実験した。表2と同じ 20 ユーザーで評価したところ、この P-DPO 派生モデルは vanilla DPO モデルを上回り、サンプル単位勝率 51.32%、ユーザー単位勝率 55% を達成した。ランダム抽出された 70 ユーザー (256 対話ターン) からなるより大規模なユーザーベースで評価すると、暗黙的ユーザーモデル専用の P-DPO は vanilla DPO モデルに対してサンプル単位勝率 65.38%、ユーザー単位勝率 72.86% を達成した。

計算・メモリ効率の観点では、P-RLHF は Personalized Soups^[19] のような既存手法と比較してメモリ・計算コストが顕著に低い。これは P-RLHF は複数の LLM や完全な報酬モデルを追加するのではなく、軽量のユーザーモデル ($N_u \ll N_l$) のみを追加するためである。

6. 結論 (Conclusions)

パーソナライズド LLM を構築するため、パーソナライズド人間フィードバックを処理するパーソナライズド RLHF フレームワーク P-RLHF を提案した。提案フレームワークは、軽量のユーザーモデルとパーソナライズド LLM を同時に学習し、利用可能であればテキスト ユーザー情報からの明示的な選好を活用し、フィードバックデータから暗黙的な選好を直接推定することを可能にし、ユーザー数の増加に対しても効率的にスケールする。提案するのは、(1) 構造的な選好仮定を捕捉するための異なるユーザーモデル設計、(2) パーソナライズド言語モデリングのための新しい学習目的 (P-DPO) である。実証的に、本手法は個々のユーザー選好により整合した応答を生成するパーソナライズド LLM を効果的に学習した。結論として、本 P-RLHF フレームワークは汎用的であり、多くの既存の RLHF バリエーションに適用可能であることを強調しておく。

※ 本論文「Personalized Language Modeling from Personalized Human Feedback」の著作権は原著者 (Xinyu Li, Ruiyang Zhou, Zachary C. Lipton, Liu Leqi) に帰属します。本日本語訳は研究・教育目的での参照を容易にするために作成された非公式の翻訳です。原論文の正式な引用が必要な場合は arXiv:2402.05133 を直接参照してください。

参考文献 (References)

1. AI@Meta. *Llama 3 model card*. 2024.
2. Mohammad Gheshlaghi Azar, et al. A general theoretical paradigm to understand learning from human preferences. 2024.
3. Yuntao Bai, et al. Training a helpful and harmless assistant with reinforcement learning from human feedback. 2022.
4. Ralph Allan Bradley and Milton E Terry. Rank analysis of incomplete block designs: I. the method of paired comparisons. 1952.
5. Tom Brown, et al. Language models are few-shot learners. *NeurIPS*, 2020.
6. Souradip Chakraborty, et al. Maxmin-rlhf: Towards equitable alignment of large language models with diverse human preferences. 2024.
7. Junyi Chen. A survey on large language models for personalized and explainable recommendations. 2023.
8. Aakanksha Chowdhery, et al. PaLM: Scaling language modeling with pathways. 2022.
9. Alexander Philip Dawid and Allan M Skene. Maximum likelihood estimation of observer error-rates using the EM algorithm. 1979.
10. Mingkai Deng, et al. RLPrompt: Optimizing discrete text prompts with reinforcement learning. 2022.
11. Abhimanyu Dubey, et al. The Llama 3 herd of models. 2024.
12. Yann Dubois, et al. AlpacaFarm: A simulation framework for methods that learn from human feedback. *NeurIPS*, 2024.
13. Xinyang Geng, et al. Koala: A dialogue model for academic research. 2023.
14. Hayit Greenspan, et al. Guest editorial: Deep learning in medical imaging. 2016.
15. Edward J Hu, et al. LoRA: Low-rank adaptation of large language models. *ICLR*, 2021.
16. EunJeong Hwang, et al. Aligning language models to user opinions. 2023.
17. Hideaki Imamura, et al. Analysis of minimax error rate for crowdsourcing and its application to worker clustering model. 2018.
18. Joel Jang, et al. Personalized soups: Personalized large language model alignment via post-hoc parameter merging. *ICLR*, 2023.
19. Dipesh Kadariya, et al. kBot: Knowledge-enabled personalized chatbot for asthma self-management. 2019.
20. Wang-Cheng Kang, et al. Do LLMs understand user preferences? Evaluating LLMs on user rating prediction. 2023.
21. Hannah Rose Kirk, et al. Personalisation within bounds: A risk taxonomy and policy framework for the alignment of large language models with personalised feedback. 2023.
22. Hannah Rose Kirk, et al. The PRISM alignment project: What participatory, representative and individualised human feedback reveals about the subjective and multicultural alignment of large language models. 2024.
23. Brian Lester, et al. The power of scale for parameter-efficient prompt tuning. *EMNLP*, 2021.
24. Cheng Li, et al. Teach LLMs to personalize. 2023.
25. Jiacheng Li, et al. Text is all you need: Learning language representations for sequential recommendation. 2023.
26. Jinming Li, et al. GPT4Rec: A generative framework for personalized recommendation and user interests interpretation. 2023.
27. Xiang Lisa Li and Percy Liang. Prefix-tuning: Optimizing continuous prompts for generation. *ACL*, 2021.
28. Zhengyi Ma, et al. One chatbot per person: Creating personalized chatbots based on implicit user profiles. 2021.
29. Aman Madaan, et al. MEMPrompt: Memory-assisted prompt editing with user feedback. 2022.

35. Rafael Rafailov, et al. Direct preference optimization: Your language model is secretly a reward model. *NeurIPS*, 2023.
36. Vikas C. Raykar, et al. Learning from crowds. *JMLR*, 2010.
37. Chris Richardson, et al. Integrating summarization and retrieval for enhanced personalization via large language models. 2023.
38. Filipe Rodrigues and Francisco Pereira. Deep learning from crowds. *AAAI*, 2018.
39. Alireza Salemi, et al. LaMP: When large language models meet personalization. *SIGIR*, 2023.
40. Alireza Salemi, et al. Optimization methods for personalizing large language models through retrieval augmentation. 2024.
41. John Schulman, et al. Proximal policy optimization algorithms. *arXiv:1707.06347*, 2017.
42. Taylor Shin, et al. AutoPrompt: Eliciting knowledge from language models with automatically generated prompts. 2020.
43. Rion Snow, et al. Cheap and fast — but is it good? Evaluating non-expert annotations for natural language tasks. *EMNLP*, 2008.
44. Nisan Stiennon, et al. Learning to summarize with human feedback. *NeurIPS*, 2020.
45. Leandro von Werra, et al. TRL: Transformer reinforcement learning. *GitHub*, 2020.
46. Ben Wang and Aran Komatsuzaki. GPT-J-6B: A 6 Billion Parameter Autoregressive Language Model. 2021.
47. Yizhong Wang, et al. How far can camels go? Exploring the state of instruction tuning on open resources. 2024.
48. Zeqiu Wu, et al. Fine-grained human feedback gives better rewards for language model training. *NeurIPS*, 2023.
49. Fan Yang, et al. PALR: Personalization aware LLMs for recommendation. 2023.
50. Rui Zheng, et al. Improving generalization of alignment with human preferences through group invariant learning. 2023.
51. Banghua Zhu, et al. Principled reinforcement learning with human feedback from pairwise or k-wise comparisons. *ICML*, 2023.
52. Daniel M Ziegler, et al. Fine-tuning language models from human preferences. *arXiv:1909.08593*, 2019.

付録 A：関連研究の追加

A.1 クラウドソーシング（Crowdsourcing）

複数のアノテータからのラベルを集約するクラウドソーシング設定では^[44,37,39]、各アノテータの信頼度を考慮するため EM アルゴリズム^[10]などの枠組みが提案されている。Imamura ら^[18]は、混同行列をクラスタレベルでモデル化し、アノテータ間の共有される混同パターンを捉える。これに着想を得て、本研究では、アノテータに関する行動仮定をクラウドソーシング文献から借りて、ユーザー選好を母集団・クラスタ・個別の各レベルでモデル化する、類似の方策をユーザーモデル構造として設計した。

A.2 条件付き自然言語生成（Conditional Natural Language Generation）

本研究はまた、事前学習済み LLM を条件付けされたテキスト生成のために、ソフトプロンプト学習により適応させる^[24,28,43,11] 関連研究と関連する。Maynez ら^[32]は LLM 能力のベンチマークを提供している。一方、本アプローチはパーソナライゼーション設定、すなわち選好データセット（伝統的なテキスト生成やアノテーションデータセットではなく）からユーザー固有表現を学習することに焦点を当てる。

付録 D：指示追従実験の詳細 (P-SOUPS)

D.1 データセット説明

P-SOUPS データセット^[19] は GPT-4 Alpaca 指示^[34] への応答に対するペアワイズ比較を含む。これらの応答は Tulu-7B^[48] からサンプリングされ、三つの異なる選好次元（専門性・情報量・スタイル）にわたり GPT-4 によりアノテーションされた。各次元について対称な選好対が存在する：

- **専門性 (Excellence / Expertise, P1):** P1A=PhD レベル、P1B=初級学生レベル
- **情報量 (Informativeness, P2):** P2A=簡潔、P2B=冗長
- **スタイル (Style, P3):** P3A=友好的、P3B=非友好的

三つの次元 × 二つの対称選好 = 合計六つの異なる選好プロファイル。各プロファイルを別ユーザーとして扱う。

D.2 実験設定

Tulu-7B をベースモデルとして SFT 後、P-DPO によりファインチューニングを行う。ユーザーモデルは個別化選好（例2）を用い、 $\alpha = 0.5$ 、 $T_u = 10$ に設定した。ユーザー テキスト 情報（明示的な選好仕様）は提供しなかったため、P-DPO はフィードバックデータから暗黙的に選好を学習する必要がある。

D.3 評価手順

文献^[19] に倣い、Koala 評価^[14] から 50 件の指示を選定し、P-DPO モデルと三つのベースライン モデル間で生成物のペアワイズ勝率を計測する。勝率は GPT-4 により AlpacaFarm ベースの枠組み^[13] 上でアノテーションされた。評価時には各ユーザーの選好プロンプトが正解として GPT-4 に提供される一方、P-DPO モデルには明示的な選好情報なしでプロンプトが与えられる。

付録 E：実世界データセットの詳細 (PRISM)

E.1 PRISM データセットの実験詳細

PRISM は豊富なアノテーションを伴うマルチターン対話データセットである^[23]。1,500 名の参加者と 8,011 件の厳選ラベル付き対話を含み、参加者の社会人口統計情報（年齢・性別・教育など）および表明選好を含む。実験では：

- まずモデルの観測外ユーザーへの汎化能力を検証するため、参加者を「観測ユーザー」と「未観測ユーザー」に分離する。
- 列車・検証・テスト分割比 6431 : 3982 を最終的に得る。
- 最大テキスト長は 800 トークンに制限する。
- SFT モデルには Llama3-8B-Instruct を用いる。
- ユーザーモデルには個別化選好（例2、T=10）およびクラスタベース選好（例3、K=10 および K=100）を用いる。

E.2 評価用ロールプレイ プロンプト

GPT-4o のロールプレイ プロンプトには次の要素が含まれる：(1) ユーザー情報（社会人口統計、自己記述、システム文字列、表明された上位三つの選好側面）；(2) フィードバックと文脈情報（当該サンプルが抽出された対話後のユーザー フィードバック、ならびに参加者の他のターンにおけるアノテーション）。これにより GPT-4o は当該ユーザーの選好を統合的に理解したうえで勝率を判定する。

E.3 生成例：「飲酒」トピック

観察されたユーザーのうち、「飲酒」という議論の余地のあるトピックについて、ユーザーはモデルに「人間の友人のように振る舞う」ことを求めている。3 モデル（vanilla DPO、Individualized P-DPO、Cluster-based P-DPO）に同じプロンプトを与えたところ：vanilla DPO は事実ベースの解説を返し、Individualized P-DPO もやや中立的な立場を取った。一方、Cluster-based P-DPO は良き聞き手として振る舞い、ユーザーの感情に共感しつつ、対話を深める応答を返した。これは P-DPO クラスタベース ユーザーモデルが、ユーザーのテキスト情報に明示的に記述されていない暗黙的なロール期待（友人のように振る舞う）を、フィードバックから学習したことを示している。

付録 F : P-RLHF 目的式の追加詳細

F.1 選好仮定のグラフィカル モデル

標準 RLHF と P-RLHF の差異をグラフィカル モデルとして整理できる。標準 RLHF ではユーザー識別 u が観測変数として扱われず、ユーザーの選好分布が無条件化される。P-RLHF ではユーザー u (テキスト情報 u^t と識別子 u^p) が条件付け変数として明示的に組み込まれ、ユーザーモデル $f_P(u)$ からユーザー埋め込み e_u を生成し、これが LLM π_P に渡される。

F.2 ユーザーモデルのパラメータ化

例 2 (個別化選好) の場合、埋め込みテーブルは $(m + 1) \times T_u \times d$ のサイズをもち、 m は既知ユーザー数、 T_u は暗黙的埋め込みのトークン長、 d は LLM トークン埋め込み次元である。例 3 (クラスタベース選好) の場合、 $V \in \mathbb{R}^{K \times T_u \times d}$ と $W^{\text{cluster}} \in \mathbb{R}^{(m+1) \times K}$ の二つの埋め込みテーブルを用い、計算量とメモリ使用量を $K \ll m$ により大幅に削減できる。

F.3 P-RLHF 目的式の他の例 : P-IPO

P-RLHF の枠組みは、DPO だけでなく Identity Preference Optimization (IPO) にも適用可能である。IPO では損失関数を二乗誤差で定義するが、P-RLHF の枠組みを用いてユーザー固有・ユーザー非依存損失に分解できる：

$$\ell_{\text{P-IPO}}(\pi) = \alpha \left((\log \pi(y^1 | x, y^0, u^t, u^p) - \log \pi(y^2 | x, y^0, u^t, u^p)) - (\log \pi(y^1 | x, y^0) - \log \pi(y^2 | x, y^0) + \frac{1}{2}) \right)^2 + (1 - \alpha) \ell_{\text{DPO}}(\pi). \quad (\text{P-IPO})$$

この一般化により、P-RLHF は RLHF 系の任意の選好最適化手法 (DPO、IPO、PPO など) に対してユーザー識別子固有・非依存損失を組み合わせた形で拡張できる点が強調される。

翻訳: 論文全文の日本語訳、原論文 arXiv:2402.05133 を参照。

© 原著者: Xinyu Li, Ruiyang Zhou, Zachary C. Lipton, Liu Leqi (2024).